



Universidade do Minho
Escola de Engenharia
Mestrado em Engenharia Informática

Perfil de Especialização em Sistemas de Armazéns de Dados

Ano Letivo de 2025/2026

Projeto em Sistemas de Data Warehousing

Filipe Abreu Mendes Fernandes pg61520

Guilherme Pinto Pinho pg60263

João Pedro Ribeiro Lopes da Silva pg59966

Paulo Alexandre Rodrigues Alves pg61537

Maio, 2026

Data da Receção	
Responsável	
Avaliação	
Observações	

Projeto em Sistemas de Data Warehousing

Filipe Abreu Mendes Fernandes pg61520

Guilherme Pinto Pinho pg60263

João Pedro Ribeiro Lopes da Silva pg59966

Paulo Alexandre Rodrigues Alves pg61537

Maio, 2026

Resumo

As cheias constituem um dos fenómenos naturais de maior impacto socioeconómico a nível global, sendo responsáveis por perdas humanas, destruição de infraestruturas e perturbações graves no funcionamento das comunidades afetadas. A crescente imprevisibilidade destes eventos, impulsionada pelas alterações climáticas, pela expansão urbana desordenada, torna cada vez mais urgente o desenvolvimento de sistemas capazes de integrar, processar e analisar grandes volumes de dados climáticos e hidrológicos, que são obtidos, através de sensores e também pela variedade destes dados que podem assumir três formas, estruturados, semi-estruturados e não estruturados.

No âmbito da unidade curricular de Projeto de Sistemas de Data Warehousing, do Mestrado em Engenharia Informática - Perfil de Especialização em Data Warehousing, da Universidade do Minho, foi proposto ao grupo de trabalho o desenvolvimento de um sistema para monitorização e previsão de cheias. Este documento descreve, de forma detalhada, o processo de análise, planeamento, conceção e implementação desse sistema, desde a definição dos seus objetivos até à construção e validação dos seus componentes funcionais.

O sistema proposto assenta num datalakehouse que combina a flexibilidade dos *datalakes* e a robustez analítica dos armazéns de dados esta arquitetura está estruturada em camadas, que permite a ingestão, transformação e análise progressiva de dados provenientes de fontes heterogéneas, como estações meteorológicas, sensores hidrológicos e o dataset *ERA5-Land*. Com base nessa infraestrutura, foram desenvolvidos indicadores de desempenho, modelos preditivos de risco de cheias e painéis de visualização de dados orientados à tomada de decisão por parte de entidades de proteção civil e gestão de risco ambiental.

Área de Aplicação: Conceção e Implementação de Sistemas de Data Warehousing aplicados à Monitorização e Previsão de Cheias

Palavras-chave: Data Lakehouse, Data Warehouse, ETL, Previsão de Cheias, Suporte à Decisão

Índice

Resumo	1
1. Definição do Sistema	7
1.1. Contexto de Aplicação	7
1.2. Delimitação do Âmbito de Aplicação	8
1.3. Motivação e Objetivos do Trabalho	8
1.4. Análise da Viabilidade do Processo	10
1.5. Recursos e Equipa de Trabalho	12
1.6. Plano de Execução do Projeto	13
2. Levantamento e Análise de Requisitos	15
2.1. Método Adotado	15
2.2. Organização dos Requisitos Levantados	16
2.3. Análise e Validação Geral dos Requisitos	25
3. Modelação Dimensional de Dados	27
3.1. Apresentação da Abordagem Realizada	27
3.2. A Matriz de Decisão	28
3.3. Definição e Caracterização de Dimensões	30
3.4. Definição e Caracterização da Tabela de Factos	32
3.4.1. Escolha do Modelo	32
3.4.2. Grão da Tabela de Factos	33
3.4.3. Granularidade Temporal	33
3.4.4. Medidas	33
3.5. Configuração dos Esquemas	33
3.6. Vistas dos Agentes de Decisão	34
3.6.1. Analista Hidrológico (AH)	34
3.6.2. Responsável de Protecção Civil (RPC)	34
3.6.3. Decisor Estratégico (DE)	34
3.6.4. Administrador do Sistema (AS)	34
4. Arquitetura Geral do Sistema	36
4.1. Apresentação Geral	36
4.2. Fontes de Dados	36
4.2.1. IPMA — Instituto Português do Mar e da Atmosfera	36
4.2.2. SNIRH — Sistema Nacional de Informação de Recursos Hídricos	37
4.2.3. ERA5-Land — Reanálise Climática do Copernicus	37
4.2.4. Configuração para usar o pipeline	38
4.3. Área de Preparação de Dados	38
4.3.1. Camada Bronze	38
4.3.2. Camada Silver — Validação e Tipagem	39
4.3.3. Fluxo de Dados Através das Camadas	39
4.4. Exploração e Visualização de Dados	39
4.4.1. Modo de acesso	39
4.4.2. Vistas do Sistema e Dashboards por Perfil	40
4.5. Aquisição de Conhecimento	45
4.5.1. Arquitectura do Pipeline ML	45
4.5.2. Fase 1 — Caracterização	45

4.5.3.	Fase 2 — Modelação Preditiva	46
4.5.4.	Fase 3 — Operacionalização	46
5.	O Povoamento de Dados	48
5.1.	Apresentação da Abordagem Realizada	48
5.2.	Mapeamento de Dados	50
5.2.1.	Bronze: Ingestão Bruta	50
5.2.2.	Bronze → Silver: Transformações	50
5.2.3.	Silver → Gold — Esquema Estrela	51
5.3.	Modelação do Sistema de Povoamento	51
5.4.	Implementação do Sistema de Povoamento	53
5.4.1.	Ingestão IPMA (ST_BronzeIPMA.cs)	53
5.4.2.	Ingestão SNIRH (ST_BronzeSNIRH.cs)	54
5.4.3.	Ingestão ERA5 (EPT_BronzeERA5 + bronze_era5.py)	54
5.4.4.	Transformações SQL (Scripts 09–14)	54
5.4.5.	Logging e Quarentena	54
5.5.	Validação e Testes	54
5.5.1.	Validação de Dados	54
5.5.2.	Validação de Transformações	55
5.5.3.	Validação de Integridade Referencial	55
5.5.4.	Validação de Performance	55
5.5.5.	Validação do Pipeline ML	55
6.	Exploração e Análise de Dados	56
6.1.	Organização geral do sistema de dashboarding	56
6.2.	Serviços de exploração e análise implementados	56
6.2.1.	Dashboard Técnico-Hidrológico (Perfil AH)	56
6.2.2.	Dashboard Meteorológico-Operacional (Perfil RPC)	57
6.2.3.	Dashboard Executivo (Perfil DE)	57
6.2.4.	Dashboard de Monitorização do Sistema (Perfil AS)	57
7.	Previsão de Cheias	58
7.1.	Definição do problema e compreensão dos elementos de análise envolvidos	58
7.2.	Seleção e preparação dos dados	59
7.3.	Identificação e fundamentação da técnica de análise	59
7.4.	Construção do modelo de previsão	60
7.4.1.	Modelo LightGBM híbrido (previsão de nível)	60
7.4.2.	Modelo LSTM (classificação de cheia)	60
7.4.3.	Scoring de risco e classificação	61
7.5.	Validação do desempenho do modelo	61
7.6.	Avaliação dos resultados	62
8.	Conclusões e Trabalho Futuro	63
8.1.	Conclusões	63
8.2.	Trabalho Futuro	64
8.2.1.	Integração efectiva com Power BI	64
8.2.2.	Correcção da classificação geográfica das estações IPMA	64
8.2.3.	Automatização do pipeline de actualização de valores reais	64
8.2.4.	Expansão dos modelos de Machine Learning	64
8.2.5.	Extensão do sistema de alertas e notificações	65
8.2.6.	Inclusão de estações de barragem no modelo de risco	65
8.2.7.	Enriquecimento com dados de radar e satélite	65
8.2.8.	Mecanismo de controlo de versões dos modelos	65
8.2.9.	Deploy em ambiente de produção	65
8.2.10.	Validação com entidades externas	65
	Bibliografia	66
9.	Lista de Siglas e Acrónimos	67

10. Anexos 68
10.1. Anexo 1 68

Lista de Figuras

Figura 1	Diagrama de Gantt relativo ao planeamento de tarefas do projeto data warehousing.	14
Figura 2	Modelo conceptual	28
Figura 3	Página 2	40
Figura 4	Página 2	40
Figura 5	Página 3	41
Figura 6	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	41
Figura 7	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	42
Figura 8	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	42
Figura 9	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	43
Figura 10	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	43
Figura 11	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	44
Figura 12	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	44
Figura 13	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	45
Figura 14	BPMN geral	48
Figura 15	BPMN camada bronze	49
Figura 16	BPMN camada silver	49
Figura 17	BPMN camada gold	49
Figura 18	BPMN datamart ML	49
Figura 19	Análise da Cobertura de Dados das Fontes Integradas na Camada Gold	68
Figura 20	Distribuição Espacial das Estações de Monitorização na Bacia do Mondego	68
Figura 21	Dimensão das Tabelas do Data Lakehouse	69
Figura 22	Análise da Distribuição e Segmentação do Risco de Cheias	69
Figura 23	Evolução Temporal dos Índices de Risco de Cheia nas Principais Estações de Monitorização .	69
Figura 24	Comparação entre os Níveis Atuais e os Níveis Previstos da Água	70
Figura 25	Comportamento Sazonal dos Níveis Hidrométricos	70

Lista de Tabelas

Tabela 1	Requisito AH01	17
Tabela 2	Requisito AH02	17
Tabela 3	Requisito AH03	18
Tabela 4	Requisito AH04	18
Tabela 5	Requisito AH05	18
Tabela 6	Requisito AH06	19
Tabela 7	Requisito AH07	19
Tabela 8	Requisito AH08	19
Tabela 9	Requisito AH09	20
Tabela 10	Requisito RPC01	20
Tabela 11	Requisito RPC02	20
Tabela 12	Requisito RPC03	21
Tabela 13	Requisito RPC04	21
Tabela 14	Requisito RPC05	21
Tabela 15	Requisito DE01	22
Tabela 16	Requisito DE02	22
Tabela 17	Requisito DE03	22
Tabela 18	Requisito DE04	23
Tabela 19	Requisito AS01	23
Tabela 20	Requisito AS02	23
Tabela 21	Requisito AS03	24
Tabela 22	Requisito AS04	24
Tabela 23	Requisito AS05	24
Tabela 24	Requisito AS06	25
Tabela 25	Requisito AS07	25
Tabela 26	Caracterização de Dimensão — dim_tempo	30
Tabela 27	Hierarquias — dim_tempo	30
Tabela 28	Caracterização de Dimensão — dim_estacao	31
Tabela 29	Caracterização de Dimensão — dim_bacia	31
Tabela 30	Caracterização de Dimensão — dim_parametro	32
Tabela 31	Pool Bronze: Ingestão de dados das 3 fontes	52
Tabela 32	Pool Silver — Validação, tipagem e transformação	52
Tabela 33	Pool Gold — Construção do esquema estrela e preparação ML	52
Tabela 34	Pool ML — Pipeline de aquisição de conhecimento (9 tarefas sequenciais)	53
Tabela 35	Dashboards por perfil de decisão	56
Tabela 36	Pipeline ML — scripts, acções e resultados	59
Tabela 37	Métricas do modelo LightGBM híbrido por horizonte de previsão	61
Tabela 38	Métricas do classificador LSTM por horizonte	61

1. Definição do Sistema

1.1. Contexto de Aplicação

Portugal é um país historicamente vulnerável a fenómenos de **cheia**, que se manifestam sobretudo sob duas formas principais: **cheias rápidas**, geralmente associadas a episódios curtos de precipitação intensa e que afetam pequenas bacias hidrográficas, sobretudo em áreas urbanas e **cheias em grandes bacias hidrográficas**, resultantes de vários dias ou semanas de precipitação contínua. Para além disso, fatores como a orografia do território, a distribuição cada vez mais irregular da precipitação ao longo do ano e a crescente pressão urbanística sobre as zonas ribeirinhas contribuem para amplificar significativamente o risco associado a estes eventos.

Regiões como o Mondego, o Baixo Tejo, o Vale do Douro e diversas bacias hidrográficas do Norte e Centro do país têm sido, ao longo das últimas décadas, palco de episódios de cheia com consequências graves, quer para as populações residentes, quer para as infraestruturas. A recorrência destes eventos, aliada à crescente imprevisibilidade introduzida pelas alterações climáticas globais, impõe uma necessidade cada vez mais premente de sistemas de monitorização, análise e previsão que sejam capazes de operar sobre grandes volumes de dados heterogêneos, em tempo útil, e de forma tecnicamente robusta.

É neste enquadramento que surge a **PreFlood**, uma empresa de consultoria e desenvolvimento tecnológico especializada em soluções de monitorização ambiental e gestão do risco hídrico. A PreFlood nasceu da iniciativa de um conjunto de amigos com experiência acumulada em projetos de gestão de recursos hídricos, tanto no contexto nacional como europeu, nomeadamente no âmbito de programas financiados pelo plano de recuperação e resiliência (PRR). A empresa presta serviços a entidades públicas e privadas, incluindo municípios, autoridades de proteção civil, concessionárias de barragens e agências de ambiente, fornecendo soluções de análise de dados climáticos e hidrológicos, relatórios de risco e sistemas de alerta.

Ao longo dos últimos anos, a PreFlood tem vindo a identificar uma lacuna significativa na forma como os dados de monitorização são recolhidos, armazenados e explorados pelos seus clientes. Na grande maioria dos casos, os dados provenientes de estações meteorológicas, sensores de nível de caudal, imagens de satélite e registos históricos de ocorrências encontram-se dispersos por sistemas distintos, sem qualquer integração efetiva entre si.

Esta fragmentação impede a realização de análises temporais e espaciais abrangentes, limita a capacidade de identificar padrões de comportamento hidrológico, embora seja difícil de prever a natureza, e inviabiliza, na prática, a construção de modelos preditivos minimamente fiáveis. Em consequência, as entidades responsáveis pela gestão do risco de cheias veem-se frequentemente obrigadas a tomar decisões críticas com base em informação incompleta, desatualizada ou de difícil interpretação.

Face a este cenário, a PreFlood decidiu investir no desenvolvimento de um sistema centralizado de suporte à decisão, assente numa arquitetura de **Datalakehouse**, que permita integrar, num único repositório, todas as fontes de dados relevantes para a monitorização e previsão de cheias. Acreditamos que esta arquitetura será ideal visto que numa análise prévia às fontes foi possível identificar fatores como a variedade dos dados, o seu grande volume e a velocidade com que chegam e queremos mantê-los de uma forma estruturada, para isso achamos a parte do warehouse ideal. Posteriormente será construído pelo menos um data mart para uso pelos algoritmos de aprendizagem automática.

Este sistema deverá servir os seus clientes possibilitando a análise histórica de eventos de cheia, a monitorização de variáveis hidrológicas e meteorológicas, e a geração de alertas e previsões de risco a curto prazo, numa margem de horas.

O sistema está, assim, concebido para operar num contexto operacional exigente, onde a qualidade, a consistência e a rastreabilidade dos dados são peças fundamentais e necessárias. Contudo, a eficácia de um sistema desta natureza não se limita à capacidade de resposta em tempo real durante a ocorrência de um evento - ela começa muito antes, na prevenção. A análise histórica de padrões hidrológicos permite fundamentar decisões estruturais de longo prazo, como a gestão preventiva de barragens e reservas de água, o dimensionamento adequado de infraestruturas de drenagem, ou o aprofundamento e requalificação de leitos de ribeiras com histórico recorrente de transbordo. Neste projeto não será abordada essa temática cabendo a uma possível extensão deste sistema ou criação de um novo.

Num cenário de cheia ativa, onde o tempo é um bem precioso, onde cada hora pode fazer a diferença entre salvar ou perder vidas, a disponibilidade imediata de informação consolidada, atualizada e interpretável é um ativo inestimável para as entidades de proteção civil e gestão de emergência. A capacidade de resposta em tempo útil pode, literalmente, significar a diferença entre a vida e a morte para as populações expostas ao risco.

1.2. Delimitação do Âmbito de Aplicação

Embora o problema das cheias se coloque à escala nacional, o presente projeto delimita explicitamente o seu âmbito de estudo ao rio Mondego, por ter a sua extensão inteiramente em território português. Esta delimitação, justificada pela razão académica seguinte:

- Demonstração do funcionamento do sistema, com um menor volume de dados

A arquitetura proposta mantém, ainda assim, carácter escalável: embora a implementação e validação incidam sobre um único rio e a respetiva bacia hidrográfica, o sistema poderá ser posteriormente replicado para outras bacias hidrográficas, desde que estejam disponíveis fontes de dados equivalentes e efetuados os ajustamentos necessários.

1.3. Motivação e Objetivos do Trabalho

A motivação para o desenvolvimento do sistema por parte da nossa empresa decorre diretamente das limitações identificadas no contexto operacional e, de forma mais ampla, do estado geral dos sistemas de monitorização e gestão do risco de cheias em Portugal e na Europa. Apesar da crescente disponibilidade de dados climáticos e hidrológicos - provenientes de redes de sensores, satélites de observação terrestre, modelos meteorológicos numéricos e registos históricos de organismos públicos como a Agência Portuguesa do Ambiente (APA) ou o Instituto Português do Mar e da Atmosfera (IPMA), a sua exploração efetiva continua a ser severamente condicionada pela ausência de infraestruturas de integração e análise adequadas. Os dados existem, mas encontram-se fragmentados, em formatos nem sempre ideais para serem usados, sem mecanismos de correlação entre si e sem qualquer estrutura que permita a sua exploração analítica de forma sistemática e reprodutível.

Esta realidade traduz-se, na prática, numa incapacidade crónica de tirar partido do conhecimento latente que esses dados encerram. Padrões de comportamento hidrológico que se repetem ao longo de décadas permanecem por identificar. Correlações entre variáveis meteorológicas e a ocorrência de eventos extremos ficam por estabelecer. Modelos preditivos que poderiam antecipar situações de risco com horas ou dias de antecedência nunca chegam a ser construídos, por falta de uma base de dados integrada, consistente e historicamente organizada com qualidade suficiente para prever essas situações. É, portanto, imperativo desenvolver uma solução que colmate estas lacunas de forma estruturada e tecnicamente fundamentada.

Surge, assim, como resposta a esta necessidade, com o objetivo geral de constituir uma plataforma centralizada de suporte à decisão para a monitorização e previsão de cheias, capaz de integrar dados heterogêneos, suportar análises históricas e em tempo real, e disponibilizar modelos preditivos e ferramentas de visualização orientadas aos diferentes perfis de utilizadores envolvidos na gestão do risco hídrico. Para a prossecução deste objetivo geral, foram definidos os seguintes objetivos específicos:

Centralização e integração de dados heterogêneos: O primeiro e mais fundamental objetivo do sistema consiste em criar um repositório único, capaz de agregar dados provenientes de fontes diversas - estações meteorológicas, sensores de nível e caudal instalados em rios e ribeiras, variáveis terrestres como saturação do solo, através do uso de datasets de reanálise, que combina observações com modelos físicos. A centralização destes dados, com garantia de consistência e rastreabilidade ao longo do tempo, é a condição **sine qua non** para que todos os restantes objetivos possam ser alcançados.

Implementação de uma arquitetura em camadas progressivas de qualidade: O sistema deverá organizar os dados ingeridos em camadas funcionais distintas - desde a camada de dados brutos, onde a informação é armazenada no seu formato original sem qualquer transformação, até à camada analítica, onde os dados se encontram limpos, validados, enriquecidos e estruturados para suporte a análises e modelos. Esta abordagem garante a rastreabilidade completa do dado desde a sua origem até à sua utilização final, e permite a evolução progressiva da qualidade da informação disponível no sistema.

Análise de padrões históricos de cheias: Com base nos dados históricos integrados, o sistema deverá ser capaz de suportar análises temporais e espaciais aprofundadas, que permitam identificar padrões recorrentes de comportamento hidrológico, estabelecer correlações entre variáveis meteorológicas e a ocorrência de eventos extremos, e caracterizar a vulnerabilidade de diferentes bacias hidrográficas e zonas ribeirinhas. Estas análises constituem um contributo essencial para o planeamento de medidas de prevenção estrutural, como a gestão de barragens, o dimensionamento de reservas de água e a requalificação de leitos de ribeiras.

Definição e monitorização de indicadores de desempenho (KPIs): O sistema deverá disponibilizar um conjunto de indicadores-chave de desempenho, baseados em métricas temporais e espaciais relevantes para a gestão do risco hídrico. Estes indicadores incluem, entre outros, o índice de precipitação acumulada por bacia hidrográfica, o nível médio e máximo dos rios por período temporal, a frequência e duração de eventos de cheia por região, e o tempo médio de resposta dos sistemas de alerta. A disponibilização destes KPIs de forma sistemática e atualizada permite às entidades responsáveis acompanhar a evolução da situação hidrológica e avaliar a eficácia das medidas implementadas.

Construção de modelos preditivos de risco de cheia: Um dos objetivos centrais do sistema é o desenvolvimento de modelos de aprendizagem automática capazes de estimar, com antecedência operacionalmente útil, o risco de ocorrência de cheia na zona em estudo. Atendendo à natureza hidrológica dos rios portugueses, frequentemente marcados por respostas rápidas a episódios de precipitação intensa, o sistema foca-se sobretudo na previsão no muito curto prazo, isto é, nas próximas horas, em vez de previsões de um ou mais dias. Pretende-se, assim, produzir previsões para janelas temporais curtas, por exemplo 1, 3 e 6 horas, mais adequadas à resposta operacional das entidades de proteção civil. Estes modelos deverão ser simples, interpretáveis e validados com base em dados históricos, de forma a garantir a sua credibilidade junto dos utilizadores finais.

Disponibilização de dashboards de apoio à decisão: O sistema deverá incluir um conjunto de painéis de visualização de dados, adaptados aos diferentes perfis de utilizadores - desde analistas técnicos que necessitam de acesso a dados granulares e indicadores detalhados, até decisores de nível estratégico que requerem uma visão agregada e de fácil interpretação da situação de risco. Estes **dashboards** constituem a interface principal entre o sistema e os seus utilizadores, e a sua qualidade e usabilidade são determinantes para a efetiva adoção do sistema pelas entidades clientes da PreFlood.

O conjunto de objetivos aqui enumerados define, de forma clara e estruturada, o âmbito e a ambição do projeto, bem como as decisões que o sistema se propõe suportar, desde o planeamento preventivo de longo prazo até à gestão operacional de emergências em contexto de cheia ativa.

A pertinência desta iniciativa é ainda corroborada pela crescente atenção que as empresas tecnológicas têm vindo a dedicar a este domínio. A Google disponibiliza atualmente o *Flood Hub*, uma plataforma de

acesso público que recorre a modelos de inteligência artificial para prever inundações em leitos de rio, cruzando imagens de satélite com modelos digitais de terreno para estimar, com antecedência de vários dias, o comportamento hidrológico de bacias em risco. Em março de 2026, a mesma empresa anunciou o *Groundsource*, uma nova plataforma com a ambição declarada de “prever o imprevisível” e de contribuir ativamente para a prevenção de catástrofes naturais de origem climática (Público, 2026). A existência destas iniciativas por parte de organizações com recursos virtualmente ilimitados não invalida, bem pelo contrário, valida o desenvolvimento de sistemas como o FloodSense: enquanto plataformas globais como o *Flood Hub* operam a uma escala geográfica abrangente mas necessariamente genérica, um sistema orientado ao contexto nacional e às especificidades hidrológicas do território português, com integração direta das fontes de dados da APA e do IPMA e com capacidade de resposta às necessidades operacionais das entidades de proteção civil portuguesas, representa uma solução complementar e de maior proximidade ao utilizador final.

Importa ainda salientar que o objetivo do sistema não é substituir estes modelos hidrometeorológicos, mas antes complementar a decisão operacional através de mecanismos analíticos e preditivos ajustados ao contexto local, com forte sensibilidade temporal e capacidade de resposta em janelas horárias curtas.

1.4. Análise da Viabilidade do Processo

A viabilidade de um projeto desta natureza deve ser analisada segundo múltiplas dimensões complementares: técnica, operacional, económica e legal, sendo necessário demonstrar, em cada uma delas, que as condições necessárias para o sucesso do desenvolvimento e da operação do sistema se encontram reunidas. A análise que se segue procura fazer essa demonstração de forma fundamentada, recorrendo a exemplos concretos que evidenciam não apenas a exequibilidade do projeto, mas também a sua pertinência e o seu potencial de impacto real.

Viabilidade Técnica. Do ponto de vista técnico, a implementação de um sistema de data lakehouse é a mais viável para o nosso projeto. Quando temos dados provenientes de várias fontes, essas mesmas fontes podem não possuir estrutura definida, podendo ser não estruturadas, semi-estruturadas ou estruturadas. Nesse contexto, uma arquitetura em lago permite armazenar e processar todos esses tipos de dados de forma unificada, mantendo flexibilidade no armazenamento.

A monitorização e previsão de cheias é hoje uma realidade plenamente alcançável, graças à maturidade das tecnologias e plataformas disponíveis no mercado. A integração de dados provenientes de fontes heterogéneas, como ficheiros CSV exportados por estações meteorológicas, APIs REST disponibilizadas pelo IPMA, e bases de dados relacionais de registos históricos é um problema conhecido, para o qual existem soluções para lidar com estas diferentes estruturas de dados.

A título de exemplo concreto, o IPMA disponibiliza publicamente, através da sua API oficial, dados de observação meteorológica em tempo real e previsões numéricas para todo o território nacional, com granularidade horária e cobertura geográfica abrangente. A APA, por sua vez, mantém o Sistema Nacional de Informação de Recursos Hídricos (SNIRH), que agrega séries históricas de caudais, níveis de albufeiras para centenas de estações hidrométricas em Portugal. Ambas as fontes são tecnicamente acessíveis, gratuitas e com formatos de dados suficientemente standardizados para permitir a sua integração no sistema sem necessidade de desenvolvimentos técnicos extraordinários.

Viabilidade Operacional. A viabilidade operacional do projeto assenta na existência de uma equipa técnica com as competências necessárias para o seu desenvolvimento, bem como na disponibilidade de infraestrutura computacional adequada para acolher o sistema. A PreFlood dispõe de uma equipa multidisciplinar com experiência comprovada em processos de engenharia, desenvolvimento de sistemas de informação e modelação hidrológica, o que garante a cobertura das diferentes áreas de conhecimento exigidas pelo projeto. Para o desenvolvimento do sistema em particular, a equipa será composta por quatro integrantes que serão responsáveis pela construção dos pipelines de ingestão, transformação, serão também encarregues da conceção do armazém de dados, em lago, pelo desenvolvimento dos modelos preditivos e por fim dos dashboards de visualização.

Do ponto de vista da infraestrutura, o sistema será desenvolvido e operado sobre um conjunto de ferramentas e plataformas do ecossistema Microsoft, escolhidas pela sua maturidade, integração nativa entre si e familiaridade por parte da equipa técnica. O armazém de dados será implementado em SQL Server. O processo de integração e transformação de dados será desenvolvido com recurso ao Visual Studio, utilizando as suas ferramentas de desenvolvimento de fluxos de dados e execução de processos ETL, que permitem modelar, de forma visual e estruturada, todo o pipeline de ingestão e transformação da informação desde as fontes até ao armazém de dados.

Para o desenvolvimento dos modelos preditivos de risco de cheia, será usado Python e utilizadas as bibliotecas Python necessárias, nomeadamente para manipulação e preparação de dados e construção de modelos de aprendizagem automática. Um objetivo central da arquitetura do sistema é garantir que estes modelos não constituam componentes isolados, mas que se encontrem devidamente integrados nas dashboards de visualização disponibilizadas aos utilizadores finais, permitindo que as previsões geradas sejam consultadas de forma direta e intuitiva no mesmo ambiente onde são acompanhados os restantes indicadores operacionais do sistema.

Viabilidade Económica. A análise económica do projeto revela um balanço claramente favorável entre o investimento necessário para o seu desenvolvimento e os benefícios operacionais e estratégicos que se espera obter com a sua implementação. Do lado dos custos, os principais componentes são os custos de desenvolvimento, associados ao tempo de trabalho da equipa técnica, os custos de infraestrutura e os custos de manutenção e operação contínua do sistema. Estes custos são, na sua maioria, previsíveis e controláveis, e beneficiam da natureza incremental da arquitetura adotada, que permite lançar uma primeira versão funcional do sistema com um subconjunto das funcionalidades previstas e ir expandindo progressivamente o seu âmbito.

Do lado dos benefícios, os ganhos económicos associados à prevenção e mitigação de cheias são amplamente documentados na literatura e em relatórios de organismos internacionais. De acordo com dados da Agência Europeia do Ambiente, os eventos de cheia na Europa são aproximadamente 47% das ocorrências extremas (European Environment Agency, 2024), com um prejuízo estimado destes eventos extremos de 44.9 mil milhões entre 2020 e 2024 (European Environment Agency, 2024), afetando infraestruturas de transporte, habitação, agricultura e serviços públicos. Estudos de custo-benefício realizados no âmbito de projetos de sistemas de alerta precoce para cheias e outros fenómenos extremos demonstram de forma consistente que, por cada euro investido, há um retorno estimado de nove euros (World Meteorological Organization, 2023). O investimento em sistemas de monitorização e previsão gera benefícios económicos significativos e, acima de tudo, contribui para a proteção de vidas, cujo valor é incalculável.

Para a nossa empresa em particular, o desenvolvimento deste sistema representa ainda uma oportunidade de diferenciação competitiva no mercado de consultoria ambiental, com a possibilidade de comercializar o sistema como um serviço gerido a municípios e entidades de proteção civil, gerando receitas recorrentes que amortizem o investimento inicial num horizonte temporal relativamente curto.

Viabilidade Legal e Regulatória. A utilização de dados provenientes de fontes públicas como o IPMA e a APA é legalmente enquadrada pelas políticas de dados abertos do Estado português, em conformidade com a Diretiva Europeia sobre Dados Abertos Diretiva 2019/1024/UE (Parlamento Europeu & Conselho da União Europeia, 2019), transposta para o ordenamento jurídico nacional pela Lei n.º 68/2021, de 26 de agosto (Assembleia da República, 2021). Os dados de observação meteorológica e hidrológica disponibilizados por estas entidades são, na sua grande maioria, de acesso livre e gratuito para fins de investigação, desenvolvimento tecnológico e prestação de serviços de interesse público, o que elimina qualquer constrangimento legal relevante à sua utilização no âmbito do nosso sistema.

Em síntese, a análise realizada nas quatro dimensões consideradas: técnica, operacional, económica e legal permite concluir que o projeto é plenamente viável, estando reunidas as condições necessárias para o seu desenvolvimento bem-sucedido e para a geração do impacto esperado junto das entidades utilizadoras do sistema.

1.5. Recursos e Equipa de Trabalho

O desenvolvimento deste sistema exige a mobilização de um conjunto diversificado de recursos, tanto humanos como materiais, cuidadosamente selecionados e enquadrados nas diferentes fases do projeto. A constituição de uma equipa técnica com capacidade, aliada às ferramentas e infraestruturas adequadas, é uma condição determinante para o sucesso do projeto. Nas subsecções seguintes, procede-se à identificação e caracterização detalhada de cada um desses recursos.

Equipa de Trabalho. A equipa responsável pelo desenvolvimento é composta por quatro elementos, com perfis técnicos complementares que cobrem as diferentes áreas de conhecimento exigidas pelo projeto. Esta dimensão foi considerada adequada face ao âmbito do sistema a desenvolver, permitindo uma distribuição equilibrada de responsabilidades sem introduzir uma sobrecarga de coordenação que pudesse comprometer a eficiência do processo de desenvolvimento.

O papel de **Gestor de Projeto** é desempenhado pelo Guilherme, com experiência prévia na coordenação de projetos. Este elemento é responsável pela planificação geral do projeto, pela monitorização do progresso das diferentes tarefas, pela gestão de riscos e pela garantia de alinhamento entre os objetivos definidos e as soluções implementadas. A sua intervenção é transversal a todas as fases do projeto, com particular relevância nas etapas de definição dos requisitos, da arquitetura geral do sistema e da validação dos entregáveis produzidos, resultados no fim do projeto.

Os dois **Engenheiros de Dados**, Paulo e João, integram a equipa com a responsabilidade de conceber e implementar os pipelines de dados. São estes elementos que desenvolvem os fluxos ETL no Visual Studio, definem o mapeamento de dados entre as fontes e o armazém, e garantem a qualidade e consistência da informação ao longo de todo o processo de integração. A sua experiência com SQL Server e com processos de modelação e transformação de dados é essencial para a correta implementação da camada de dados do sistema.

O **Especialista em Modelação Dimensional e Armazéns de Dados**, Filipe, é o elemento da equipa com maior profundidade de conhecimento nas metodologias de modelação multidimensional, nomeadamente na abordagem de Kimball. É este elemento que lidera a definição da matriz de decisão, a caracterização das dimensões e tabelas de factos, e a configuração dos esquemas do armazém de dados. O seu papel é igualmente relevante na validação do modelo dimensional face aos requisitos de decisão levantados, assegurando que a estrutura do armazém de dados responde de forma adequada às necessidades analíticas dos diferentes perfis de utilizadores.

O **Cientista de Dados**, Paulo, é o elemento responsável pelo desenvolvimento dos modelos preditivos de risco de cheia, com recurso a bibliotecas Python especializadas em manipulação de dados e aprendizagem automática. Este elemento lidera ainda o processo de integração dos modelos desenvolvidos nos dashboards de visualização, garantindo que as previsões geradas se encontram acessíveis aos utilizadores finais de forma clara e contextualizada. A sua participação é especialmente relevante nas fases finais do projeto, dedicadas à construção, validação e avaliação dos modelos preditivos.

Recursos Materiais e Tecnológicos. Para além dos recursos humanos, o desenvolvimento requer a disponibilização de um conjunto de recursos materiais e tecnológicos, que se descrevem de seguida.

O **Bizagi Modeler** é a ferramenta adotada pela equipa para a modelação dos processos de negócio e dos fluxos de integração de dados do sistema, com recurso à notação BPMN (Business Process Model and Notation). A utilização de uma ferramenta dedicada à modelação de processos justifica-se pela necessidade de documentar de forma rigorosa, clara e estandardizada os diferentes fluxos de trabalho que compõem o sistema, desde os processos de ingestão e transformação de dados até aos fluxos de geração de alertas e atualização dos modelos preditivos. O Bizagi Modeler, sendo uma ferramenta gratuita, constitui uma escolha natural para este fim, permitindo produzir diagramas de processo de qualidade profissional que servirão de base tanto à implementação técnica dos fluxos como à sua documentação no presente relatório.

O **Indyco Builder** é a ferramenta utilizada pela equipa para a modelação dimensional do armazém de dados. Trata-se de uma plataforma especializada na conceção e documentação de modelos multidimensionais, que permite desenhar de forma visual e estruturada os data marts com as tabelas de factos,

as dimensões, as hierarquias, as medidas. A sua adoção no projeto justifica-se pela clareza e rigor dos diagramas que produz, que facilitam tanto o processo de desenvolvimento iterativo do modelo como a sua comunicação e validação junto dos restantes elementos da equipa e dos stakeholders do projeto.

O **SQL Server** constitui o sistema de gestão de base de dados sobre o qual será implementado o armazém de dados. A escolha desta plataforma justifica-se pela riqueza das suas funcionalidades e pela sua integração nativa com as restantes ferramentas do ecossistema Microsoft utilizadas no projeto. O SQL Server suportará o armazenamento e a gestão de toda a informação estruturada do sistema, desde os dados brutos ingeridos das fontes até às tabelas de factos e dimensões do modelo dimensional.

O **Visual Studio**, com os seus serviços de integração de dados, é a plataforma central para o desenvolvimento dos processos ETL do sistema. A sua interface gráfica de modelação de fluxos de dados permite desenhar, de forma visual e estruturada, todos os processos de extração, transformação e carregamento de dados, facilitando a compreensão e a manutenção dos pipelines implementados. A capacidade de executar diretamente comandos SQL no contexto dos fluxos de dados, bem como de parametrizar e agendar a execução dos processos, torna esta ferramenta particularmente adequada às necessidades do projeto.

As **bibliotecas Python** utilizadas no desenvolvimento dos modelos preditivos, nomeadamente para manipulação e análise de dados, computação numérica e construção de modelos de aprendizagem automática constituem o ecossistema tecnológico de referência para a componente de ciência de dados do projeto. A sua escolha é justificada pela sua maturidade, pela extensão da documentação disponível, pela integração entre si e pela familiaridade da equipa com estas ferramentas, desenvolvida ao longo de projetos anteriores, foram usadas as seguintes bibliotecas:

- pyodbc>=5.3.0
- numpy>=2.4.0
- pandas>=3.0.0
- lightgbm>=4.6.0
- tensorflow>=2.21.0
- scikit-learn>=1.8.0
- hdbscan>=0.8.40
- scipy>=1.17.0
- matplotlib>=3.10.0
- seaborn>=0.13.2
- contextily>=1.7.0

Finalmente, os elementos da equipa deverão estar equipados com os recursos de hardware, como um computador. Para operações computacionalmente mais exigentes, nomeadamente o treino de modelos preditivos sobre grandes volumes de dados, será considerada a utilização pontual de capacidade de computação adicional, disponibilizada através de serviços de nuvem.

1.6. Plano de Execução do Projeto

O planeamento da execução do projeto foi elaborado tendo em conta a natureza iterativa das diferentes fases de desenvolvimento de um sistema de data lakehousing, bem como os condicionalismos temporais inerentes ao semestre letivo em que o projeto se insere. O horizonte temporal disponível para o desenvolvimento do sistema compreende treze semanas de trabalho efetivo, distribuídas entre os meses de fevereiro e maio de 2026. A planificação das tarefas foi representada sob a forma de um diagrama de Gantt, que ilustra de forma detalhada a sequência, duração e sobreposição das diferentes etapas do projeto, associando cada uma delas aos elementos da equipa responsáveis pela sua execução.

A primeira fase do projeto, correspondente à **Definição do Sistema**, ocupa as duas primeiras semanas e engloba a contextualização e fundamentação do caso de estudo, a análise de viabilidade do projeto e a definição dos recursos, da equipa e do plano de execução. Trata-se de uma fase de natureza essencialmente analítica e documental, cujo produto principal é o presente relatório na sua componente introdutória. O período de duas semanas foi considerado adequado para garantir uma fundamentação sólida do projeto antes de se avançar para as fases de recolha de requisitos e modelação.

A fase de **Levantamento e Análise de Requisitos** decorre entre as semanas dois e três. Esta fase compreende a identificação dos agentes de decisão envolvidos no sistema, o levantamento dos respetivos requisitos de análise e decisão, e a sua validação e organização. A sobreposição com a fase anterior é justificada pelo facto de que a identificação dos perfis de utilizador pode e deve começar a ser esboçada logo na fase inicial de contextualização do sistema.

O maior bloco temporal do projeto é ocupado pela fase de **Modelação Dimensional de Dados**, que se estende desde o final da terceira semana até ao final da sexta semana. Esta duração é justificada pela sua complexidade e a qualidade que o modelo dimensional exige, pois é a qualidade analítica de todo o sistema. A fase divide-se em três etapas sequenciais: a definição da granularidade, a caracterização das dimensões e tabelas de factos, da matriz de decisão e a configuração dos esquemas e vistas do armazém de dados.

Em paralelo com a fase de modelação, e a partir da quinta semana, decorre a fase de **Arquitetura Geral do Sistema**, que se estende até ao final da sétima semana. Esta sobreposição é intencional e metodologicamente justificada: à medida que o modelo dimensional vai ganhando forma, torna-se possível definir com crescente precisão a arquitetura técnica do sistema que o irá suportar, nomeadamente no que respeita à identificação e caracterização das fontes de dados, à definição da área de preparação e do armazém de dados, e à caracterização dos sistemas de visualização e aquisição de conhecimento.

A fase de **Povoamento de Dados**, que engloba o mapeamento, modelação BPMN, implementação e validação dos pipelines ETL, ocupa um bloco de quatro semanas, da sétima à décima semana. Trata-se da fase de maior complexidade técnica do projeto, onde se concretizam, em código e fluxos de integração, as decisões de modelação e arquitetura tomadas nas fases anteriores. O período de quatro semanas foi definido para acomodar a inevitável iteratividade do processo de desenvolvimento e validação dos pipelines, bem como eventuais ajustes ao mapeamento de dados decorrentes de problemas identificados.

As fases de **Exploração e Análise de Dados** e de **Previsão de Cheias** decorrem em paralelo entre as semanas dez e doze, refletindo a natureza complementar destas duas componentes do sistema. O desenvolvimento dos dashboards e a construção dos modelos preditivos partilham a mesma base de dados e os mesmos requisitos de análise, pelo que a sua execução simultânea favorece a integração dos modelos nas interfaces de visualização, que constitui um dos objetivos técnicos centrais do projeto.

A fase final, dedicada à **Redação do Relatório e Entrega**, estende-se durante o projeto total, mas com mais ênfase no relatório final desde a décima primeira semana até ao final da décima terceira semana, em sobreposição com as fases anteriores. A documentação do trabalho realizado deve ser produzida de forma progressiva ao longo do projeto. A décima terceira semana é reservada para a revisão final, integração de todos os capítulos e submissão do documento.

O diagrama de Gantt elaborado para o projeto é apresentada na Figura 1.




Figura 1: Diagrama de Gantt relativo ao planeamento de tarefas do projeto data warehousing.

2. Levantamento e Análise de Requisitos

2.1. Método Adotado

O levantamento de requisitos constitui uma das fases mais críticas e determinantes de qualquer projeto de sistemas de suporte à decisão. No caso específico do sistema de data lakehousing proposto, esta fase assume uma importância acrescida, dado que os agentes de decisão envolvidos apresentam perfis técnicos e operacionais muito distintos entre si, desde analistas de dados e engenheiros hidrológicos até responsáveis de proteção civil. Esta diversidade de utilizadores exige uma abordagem de levantamento suficientemente abrangente e flexível para capturar necessidades de informação de naturezas distintas, com diferentes níveis de detalhe, diferentes horizontes temporais e diferentes finalidades analíticas.

Atendendo à natureza analítica do sistema a implementar, a equipa adotou uma abordagem mista para o levantamento de requisitos, combinando técnicas qualitativas e analíticas que permitissem, por um lado, compreender os processos de decisão e, por outro, identificar de forma rigorosa os dados, indicadores, métricas e funcionalidades necessários ao suporte dessas decisões. As técnicas adotadas foram as seguintes:

Entrevistas. A técnica principal de levantamento de requisitos adotada consistiu na realização de entrevistas com representantes dos diferentes perfis de agentes de decisão identificados para o sistema. As entrevistas foram consideradas a técnica mais adequada para este contexto, dado que permitem ao entrevistador seguir um guião de questões predefinido mas com espaço para o entrevistado explorar livremente aspetos que considere importantes e que poderiam não ter sido antecipados pela equipa de desenvolvimento. Esta flexibilidade revelou-se particularmente relevante num domínio como o da monitorização e previsão de cheias, em que coexistem necessidades técnicas, operacionais e estratégicas, nem sempre totalmente formalizadas à partida. Foram realizadas entrevistas com representantes de três perfis distintos: um técnico superior da Agência Portuguesa do Ambiente com responsabilidades na monitorização de bacias hidrográficas, um responsável pela proteção civil de um município com historial recorrente de eventos de cheia, e um analista de dados com experiência em sistemas de monitorização ambiental. Cada entrevista teve uma duração aproximada de noventa minutos e foi documentada através de uma ata elaborada no próprio dia pelo elemento da equipa responsável pela sua condução. As atas produzidas foram posteriormente partilhadas com os entrevistados para validação e correção de eventuais imprecisões, reforçando a credibilidade e a fiabilidade da informação recolhida.

A utilização de entrevistas permitiu identificar não apenas requisitos explícitos, enunciados diretamente pelos entrevistados, mas também requisitos implícitos, inferidos a partir da descrição dos seus processos de trabalho, das dificuldades sentidas no acesso à informação e das limitações dos sistemas atualmente utilizados. Desta forma, esta técnica contribuiu de forma decisiva para a compreensão dos processos de decisão subjacentes ao problema em estudo e para a identificação das necessidades de suporte analítico a acomodar no sistema.

Análise documental. Em complemento às entrevistas, a equipa procedeu à análise de um conjunto de documentos relevantes para a caracterização do domínio de aplicação e das necessidades informacionais dos agentes de decisão. Os documentos analisados incluíram relatórios técnicos de eventos de cheia publicados pela Agência Portuguesa do Ambiente (APA) e pelo Instituto Português do Mar e da Atmosfera (IPMA), planos municipais de emergência de proteção civil de municípios com historial de cheias, fichas técnicas de estações hidrométricas e meteorológicas do Sistema Nacional de Informação de Recursos Hídricos (SNIRH), e especificações de formatos de dados das APIs públicas disponibilizadas pelo IPMA.

A análise destes documentos permitiu identificar um conjunto significativo de requisitos implícitos, nomeadamente no que respeita à periodicidade de atualização dos dados, ao detalhe temporal e espacial necessário para a análise, às principais variáveis de observação utilizadas no domínio e às necessidades de rastreabilidade e consistência da informação. Para além disso, esta técnica contribuiu para enquadrar melhor a terminologia do domínio e para reduzir ambiguidades na formulação posterior dos requisitos.

Do ponto de vista metodológico, a análise documental teve ainda um papel importante na triangulação da informação recolhida nas entrevistas. Sempre que possível, as necessidades reportadas pelos agentes de decisão foram confrontadas com documentação técnica e operacional do domínio, permitindo distinguir necessidades conjunturais de necessidades efetivamente estruturais para o sistema. Este processo aumentou a robustez do levantamento efetuado e reduziu o risco de o catálogo final de requisitos refletir apenas perceções individuais ou contextos de utilização demasiado localizados.

Reuniões de revisão e validação. O processo de levantamento de requisitos foi complementado por um conjunto de reuniões internas de revisão e validação, realizadas entre os elementos da equipa de desenvolvimento, com o objetivo de discutir, consolidar e validar os requisitos recolhidos através das técnicas anteriores. A realização destas reuniões permitiu garantir que todos os elementos da equipa partilhavam uma compreensão comum dos requisitos do sistema e que eventuais ambiguidades, redundâncias, ou contradições entre requisitos foram detetadas e resolvidas antes do início da fase de modelação dimensional. Estas sessões desempenharam também um papel importante na organização do catálogo de requisitos segundo categorias coerentes com a arquitetura funcional do sistema, facilitando a sua rastreabilidade ao longo das fases seguintes do projeto.

A combinação destas três técnicas: entrevistas, análise documental e reuniões de revisão, permitiu construir um catálogo de requisitos abrangente, consistente e validado pelos elementos, que serviu de base para todas as decisões de modelação e implementação tomadas nas fases subsequentes do projeto. Em particular, esta abordagem permitiu assegurar que os requisitos identificados refletem simultaneamente os processos reais de decisão dos utilizadores, as exigências técnicas do domínio de aplicação e as necessidades próprias de um sistema de Data Warehousing orientado ao suporte à decisão. Deste modo, o levantamento realizado não constitui apenas uma etapa preliminar do projeto, mas antes o referencial estruturante que sustenta a modelação dos dados, o desenho da arquitetura e a definição dos mecanismos de análise e visualização que o sistema virá a disponibilizar.

2.2. Organização dos Requisitos Levantados

Concluída a fase anterior, a equipa de desenvolvimento procedeu à organização e estruturação dos requisitos levantados, com o objetivo de produzir um conjunto de requisitos coerente, não redundante e passível de ser utilizado como referência direta para as fases de modelação dimensional e implementação do sistema. O processo de organização adotado seguiu uma abordagem baseada nos perfis de agentes de decisão identificados. Sendo agrupado os requisitos de acordo com a área de decisão a que se referem e com o perfil de utilizador que os expressou ou que deles beneficia primariamente.

Adicionalmente, cada requisito foi enriquecido com atributos relevantes para sistemas de Data Warehousing, nomeadamente a definição explícita de métricas, granularidade temporal e espacial, e o seu contributo para os processos de decisão. Sempre que aplicável, foi também considerada a necessidade de suporte a análise histórica (time-variant), diferentes níveis de agregação e consistência entre dimensões, garantindo alinhamento com os princípios de modelação dimensional.

Para além da caracterização funcional e analítica de cada requisito, a equipa optou por substituir a noção genérica de prioridade por uma escala ordinal de necessidade de implementação, com valores entre 1 e 5. Esta opção permite representar de forma mais rigorosa o grau de indispensabilidade de cada requisito no contexto da solução proposta, distinguindo requisitos essenciais à operacionalização mínima do sistema de requisitos desejáveis, mas não críticos numa primeira versão.

A escala adotada é a seguinte:

- 1 – Residual: requisito opcional, sem impacto direto no funcionamento base do sistema;
- 2 – Reduzida: requisito útil, mas facilmente diferível;
- 3 – Moderada: requisito relevante, com impacto funcional ou analítico intermédio;
- 4 – Elevada: requisito muito importante para a qualidade global da solução;
- 5 – Crítica: requisito indispensável para o cumprimento dos objetivos centrais do sistema.

Foram ainda identificados quatro perfis de agentes de decisão, cada um com responsabilidades operacionais distintas e necessidades analíticas específicas:

- **Analista Hidrológico (AH):** responsável pela monitorização técnica das variáveis hidrológicas e meteorológicas e pela interpretação dos dados recolhidos pelas redes de sensores;
- **Responsável de Proteção Civil (RPC):** encarregue da coordenação operacional da resposta a eventos de cheia e da emissão de alertas e recomendações às populações;
- **Decisor Estratégico (DE):** com responsabilidades de planeamento de longo prazo, alocação de recursos e definição de políticas de gestão do risco hídrico;
- **Administrador do Sistema (AS):** responsável pela operação, manutenção e governação técnica do sistema.

AH01 – Consulta de Precipitação por Estação e Período

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: Precipitação horária, acumulado 24h, máximo diário, total mensal

Granularidade Temporal: Horária / Diária / Mensal

Dimensão Espacial: Estações

Objetivo: Analisar registos de precipitação para identificar padrões e eventos extremos, agregando por hora, dia ou mês, de forma a monitorizar zonas com maior acumulação e apoiar a deteção precoce de cheias

Necessidade de Implementação: 5 – Crítica

Tabela 1: Requisito AH01

Descrição: Permite consultar a precipitação horária registada nas estações, com agregação diária ou mensal

AH02 – Consulta de Níveis Hidrológicos e Caudais

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: Nível instantâneo, cota de albufeira, caudal médio diário

Granularidade Temporal: Horária

Dimensão Espacial: Estações

Objetivo: Monitorizar níveis de água e caudais nas estações hidrométricas da bacia do Mondego, permitindo filtrar por estação, nível instantâneo, caudal médio diário código e por período temporal.

Necessidade de Implementação: 5 – Crítica

Tabela 2: Requisito AH02

Descrição: Permite consultar os níveis instantâneos, cotas de albufeira e caudais médios diários das estações.

AH03 – Comparação com Percentis Históricos

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: P50, P95, P99, máximo histórico

Granularidade Temporal: Referência estática por estação

Dimensão Espacial: Estação

Objetivo: Comparar valores atuais com a distribuição histórica (percentis P50–P99 e máximo) para detetar anomalias e avaliar a gravidade relativa de medições correntes face ao histórico de cada estação.

Necessidade de Implementação: 5 – Crítica

Tabela 3: Requisito AH03

Descrição: Usar percentis e máximo histórico por estação e parâmetro de forma a usar estes limiares para classificar o risco.

AH04 – Catálogo de Eventos de Cheia Históricos

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: Início, pico, fim, duração, valor de pico, taxa de subida, precipitação antecedente

Granularidade Temporal: Evento discreto

Dimensão Espacial: Estação

Objetivo: Identificar e caracterizar todos os eventos de cheia ocorridos historicamente, incluindo duração, valor de pico, taxa de subida e condições antecedentes (precipitação e saturação do solo), com base em percentis

Necessidade de Implementação: 4 – Elevada

Tabela 4: Requisito AH04

Descrição: Analisar toda a série temporal e identificar eventos de cheia, incluindo início, pico, fim, duração, valor de pico, taxa de subida e condições antecedentes.

AH05 – Análise do Impacto da Precipitação no Caudal e Tempo de Resposta da Bacia

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: Coeficiente de correlação; tempo de resposta (horas)

Granularidade Temporal: Evento, período histórico

Dimensão Espacial: Bacia hidrográfica

Objetivo: Identificar como variações na precipitação influenciam o aumento do caudal, permitindo determinar tempos médios de resposta das bacias hidrográficas e apoiar a previsão de situações de cheia com base em padrões históricos.

Necessidade de Implementação: 5 - Crítica

Tabela 5: Requisito AH05

Descrição: Permite analisar a relação entre os valores de precipitação registados e as alterações observadas no caudal, identificando quanto tempo demora uma bacia hidrográfica a responder a episódios de chuva intensa e avaliando o impacto desses eventos nos níveis de caudal observados.

AH06 – Avaliação da Saturação do Solo para Identificação de Zonas com Maior Risco de Cheia**Agente de Decisão:** Analista Hidrológico**Indicadores / Métricas:** Índice de saturação do solo (%) por região**Granularidade Temporal:** Diário, semanal, mensal**Dimensão Espacial:** Região → Bacia**Objetivo:** Avaliar o grau de saturação do solo e a precipitação acumulada recente, permitindo identificar regiões onde a capacidade de absorção do solo se encontra reduzida e existe maior probabilidade de escorrência superficial e ocorrência de cheias.**Necessidade de Implementação:** 4 - Elevada

Tabela 6: Requisito AH06

Descrição: Permite analisar o nível de saturação do solo e a precipitação acumulada nos períodos anteriores, identificando regiões onde o solo apresenta baixa capacidade de absorção de água, aumentando o risco de escorrência superficial, subida rápida do caudal e ocorrência de cheias.

AH07 – Exportação de Séries Temporais de Precipitação, Caudal e Variáveis Hidrológicas**Agente de Decisão:** Analista Hidrológico**Indicadores / Métricas:** Número de registos exportados; intervalo temporal selecionado; formato de exportação (CSV, JSON)**Granularidade Temporal:** Configurável (hora → ano)**Dimensão Espacial:** Seleccionável**Objetivo:** Permitir exportar séries temporais históricas de precipitação, caudal e outras variáveis hidrológicas, possibilitando a utilização dos dados em ferramentas externas de análise, visualização e modelação.**Necessidade de Implementação:** 3 - Moderada

Tabela 7: Requisito AH07

Descrição: Permite exportar séries temporais para exploração externa, integração com ferramentas analíticas e reutilização em modelos avançados. É útil, mas não é indispensável para a primeira versão operacional do sistema.

AH08 – Visualização Geográfica da Precipitação para Identificação de Zonas com Maior Risco de Cheia**Agente de Decisão:** Analista Hidrológico**Indicadores / Métricas:** Precipitação (mm) localização**Granularidade Temporal:** Hora, dia**Objetivo:** Permitir analisar a distribuição espacial da precipitação registada, identificando regiões com concentrações elevadas de chuva e zonas potencialmente mais expostas ao risco de cheia.**Necessidade de Implementação:** 4 - Elevada

Tabela 8: Requisito AH08

Descrição: Permite representar geograficamente os valores de precipitação registados nas estações meteorológicas, possibilitando identificar zonas com maiores acumulações de chuva, localizar focos de precipitação intensa e comparar a distribuição espacial da precipitação entre diferentes regiões.

AH09 – Análise da Capacidade e Evolução dos Níveis de Albufeiras e Reservatórios

Agente de Decisão: Analista Hidrológico

Indicadores / Métricas: Volume armazenado (hm³) e percentagem de capacidade total (%); variação face ao período anterior (%).

Granularidade Temporal: Diário, mensal

Objetivo: Permitir analisar a evolução dos níveis de armazenamento de água em albufeiras e reservatórios, identificando situações próximas da capacidade máxima, variações significativas no armazenamento e condições que possam influenciar o risco hidrológico da bacia.

Necessidade de Implementação: 4 - Elevada

Tabela 9: Requisito AH09

Descrição: Permite monitorizar o armazenamento de água em albufeiras e reservatórios, bem como a sua variação histórica, apoiando decisões de gestão hídrica e leitura do contexto da bacia.

RPC01 – Avaliação de Risco por Estação

Agente de Decisão: Responsável Protecção Civil

Indicadores / Métricas: Nível de risco (1-5), categoria (BAIXO/MODERADO/ALTO/CRÍTICO), cor de alerta

Granularidade Temporal: Horária

Dimensão Espacial: Estação

Objetivo: Avaliar rapidamente o nível de risco de cheia em cada estação, com classificação automática (BAIXO a CRÍTICO) baseada em percentis históricos, visualização por cores (Verde a Vermelho Escuro) e flag de risco elevado.

Necessidade de Implementação: 5 – Crítica

Tabela 10: Requisito RPC01

Descrição: Deverá ser possível identificar risco como (BAIXO/MODERADO/ALTO/CRÍTICO).

RPC02 – Emissão Automática de Alertas por Ultrapassagem de Limiares Críticos

Agente de Decisão: Responsável de Protecção Civil

Indicadores / Métricas: Número de alertas emitidos e tempo médio de resposta (minutos)

Granularidade Temporal: Tempo real, evento

Objetivo: Permitir a emissão automática de alertas operacionais quando valores críticos de precipitação, caudal ou risco de cheia ultrapassem limiares definidos, permitindo acelerar a resposta operacional e apoiar a tomada de decisão.

Necessidade de Implementação: 4 - Elevada

Tabela 11: Requisito RPC02

Descrição: Permite gerar automaticamente alertas quando variáveis hidrológicas, como precipitação, caudal ou nível de risco de cheia, ultrapassam limiares críticos definidos, permitindo acelerar a mobilização de recursos, reforçar a vigilância e reduzir a dependência de monitorização manual contínua.

RPC03 – Probabilidade de Cheia (LSTM)

Agente de Decisão: Responsável Protecção Civil

Indicadores / Métricas: Probabilidade de cheia, horizonte (6h/12h/24h), flag flood_alert, threshold usado

Granularidade Temporal: Horária

Dimensão Espacial: Estação SNIRH (naturais)

Objetivo: Conhecer a probabilidade de cheia nos próximos horizontes temporais (6h, 12h, 24h) através de modelos LSTM

Necessidade de Implementação: 4 – Elevada

Tabela 12: Requisito RPC03

Descrição: Treinar modelos de ML para classificação de cheia a 6h, 12h e 24h.

RPC04 – Painel Integrado de Monitorização Operacional do Risco de Cheia

Agente de Decisão: Responsável de Protecção Civil

Indicadores / Métricas: Caudal, precipitação, risco

Granularidade Temporal: Tempo real, histórico

Dimensão Espacial: Multi-nível (região → município → estação)

Objetivo: Disponibilizar uma visão consolidada das variáveis críticas relacionadas com o risco de cheia, permitindo ao responsável de protecção civil monitorizar a situação operacional, identificar zonas prioritárias e analisar informação detalhada por dimensão temporal e geográfica.

Necessidade de Implementação: 5 - Crítica

Tabela 13: Requisito RPC04

Descrição: Permite apresentar num único painel operacional as principais variáveis associadas ao risco de cheia, incluindo precipitação, caudal, níveis de risco e alertas ativos, permitindo obter rapidamente uma visão consolidada da situação e explorar informação detalhada por região, município ou estação.

RPC05 – Previsão do Nível Hidrométrico para Antecipação de Situações de Cheia

Agente de Decisão: Responsável de Protecção Civil

Indicadores / Métricas: Nível (m) e intervalo confiança

Granularidade Temporal: horária, diária

Dimensão Espacial: Estação → Bacia

Objetivo: Disponibilizar previsões de curto prazo sobre a evolução do nível da água nos rios, permitindo antecipar situações críticas, identificar zonas potencialmente afetadas e apoiar decisões operacionais preventivas.

Necessidade de Implementação: 5 - Crítica

Tabela 14: Requisito RPC05

Descrição: Permite estimar a evolução esperada do nível da água nos rios, por estação hidrométrica e bacia hidrográfica, permitindo identificar subidas previstas do nível da água e apoiar decisões relacionadas com reforço operacional, emissão de alertas e medidas preventivas.

DE01 – Análise da Evolução Histórica e Recorrência de Eventos de Cheia

Agente de Decisão: Decisor Estratégico

Indicadores / Métricas: Número cheias, Frequência média anual de ocorrência e Variação anual da frequência e severidade (%)

Granularidade Temporal: Ano, década

Dimensão Espacial: Região → Bacia

Objetivo: Permitir avaliar a evolução de longo prazo dos eventos de cheia, identificando tendências históricas que apoiem decisões relacionadas com investimento em infraestruturas de mitigação, planeamento territorial e políticas de adaptação ao risco hidrológico.

Tipo de Requisito: Analítico

Necessidade de Implementação: 5 - Crítica

Tabela 15: Requisito DE01

Descrição: Permite analisar a frequência, severidade e distribuição temporal dos eventos de cheia ao longo de vários anos, permitindo identificar tendências de crescimento, alterações nos padrões históricos e mudanças na recorrência dos eventos.

DE02 – Comparação do Risco Hidrológico entre Estações para Identificação de Zonas Prioritárias

Agente de Decisão: Decisor Estratégico

Indicadores / Métricas: Nível de risco, categoria, estações com risco elevado

Granularidade Temporal: Tempo real

Dimensão Espacial: Bacia do Mondego (comparação entre estações)

Objetivo: Identificar as estações com maior risco para alocação de recursos, comparando nível de risco, flag de risco elevado e predições entre todas as estações da bacia numa única vista agregada.

Necessidade de Implementação: 4 – Elevada

Tabela 16: Requisito DE02

Descrição: Permite comparar níveis de risco observados entre diferentes estações ao longo do tempo, identificando regiões com maior recorrência de situações críticas e avaliando diferenças na exposição ao risco hidrológico.

DE03 – Avaliação Comparativa das Condições Antes e Após Eventos de Cheia

Agente de Decisão: Decisor Estratégico

Indicadores / Métricas: Valor inicial, pico e final, duração, taxa de subida dos níveis, precipitação antecedente

Granularidade Temporal: Evento discreto

Dimensão Espacial: Estação SNIRH

Objetivo: Permitir analisar as características dos eventos de cheia comparando condições anteriores, evolução durante o evento e estado após ocorrência, permitindo avaliar severidade, velocidade de propagação e fatores que contribuíram para a ocorrência do evento.

Necessidade de Implementação: 3 – Moderada

Tabela 17: Requisito DE03

Descrição: Permite analisar cada evento de cheia individualmente, comparando condições hidrológicas antes, durante e após o evento, incluindo evolução dos níveis observados, duração, velocidade de subida e influência de fatores antecedentes como precipitação acumulada e saturação do solo.

DE04 – Análise de Tendências Climáticas e Hidrológicas de Longo Prazo

Agente de Decisão: Decisor Estratégico

Indicadores / Métricas: Tendência de variação da precipitação média (mm/ano), Tendência de variação da temperatura média (°C/década), Frequência de eventos extremos por período (nº eventos/ano ou década), Intensidade média e máxima de eventos extremos (mm/h)

Granularidade Temporal: Anual e decadal, com suporte a análise histórica (time-variant) e comparação entre períodos homólogos

Objetivo: Permitir analisar a evolução de longo prazo das variáveis climáticas e hidrológicas, identificando alterações na frequência e intensidade dos eventos extremos, de forma a apoiar decisões relacionadas com planeamento territorial, adaptação climática e mitigação do risco de cheia.

Tipo de Requisito: Analítico

Necessidade de Implementação: 4 - Elevada

Tabela 18: Requisito DE04

Descrição: Permite analisar a evolução histórica da precipitação, temperatura e ocorrência de eventos extremos, identificando alterações nos padrões climáticos e hidrológicos que possam influenciar o risco futuro de cheias e apoiar decisões de adaptação.

AS01 – Monitorização das Fontes de Dados

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Estado operacional das fontes (ativo/inativo), Número de falhas de ingestão por período, Tempo médio de ingestão (min), Taxa de sucesso das ingestões (%)

Granularidade Temporal: Tempo real, horário e diário

Dimensão Espacial: Fonte de dados → Estação → Região

Objetivo: Garantir a disponibilidade e a pontualidade da ingestão de dados de todas as fontes integradas no sistema, detetando e sinalizando rapidamente qualquer falha ou degradação no processo de recolha de dados

Tipo de Requisito: Técnico / Monitorização

Necessidade de Implementação: 5 - Crítica

Tabela 19: Requisito AS01

Descrição: Permite acompanhar o estado operacional das fontes, tempos de ingestão e falhas, garantindo que os dados chegam ao sistema com regularidade e pontualidade.

AS02 – Histórico de Execuções ETL

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Estado das execuções (sucesso/falha), Duração dos processos (min), Volume de registos processados, Taxa de erro (%)

Granularidade Temporal: Por execução; histórico diário e mensal

Dimensão Espacial: Processo ETL → Fonte de dados

Objetivo: Permitir auditar e analisar historicamente os processos ETL executados, identificando falhas recorrentes, atrasos, degradação de desempenho e oportunidades de otimização nos processos de integração de dados.

Tipo de Requisito: Técnico / Auditoria

Necessidade de Implementação: 5 - Crítica

Tabela 20: Requisito AS02

Descrição: Permite monitorizar e armazenar o histórico das execuções dos processos ETL, incluindo informação sobre sucesso, falhas, duração, volume processado e erros ocorridos, permitindo identificar problemas recorrentes e avaliar o desempenho do pipeline de integração.

AS03 – Configuração e Gestão de Limiares de Alerta

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Número de limiares configurados por variável, Histórico de alterações aos limiares e Frequência de atualização

Granularidade Temporal: Histórico de alterações (data/hora)

Objetivo: Permitir configurar e atualizar centralmente os limiares utilizados na geração automática de alertas, garantindo que diferentes regiões, municípios ou estações utilizam valores ajustados às respetivas condições hidrológicas e níveis de risco.

Necessidade de Implementação: 5 - Crítica

Tabela 21: Requisito AS03

Descrição: Permite configurar, atualizar e manter os limiares utilizados pelos mecanismos automáticos de alerta, garantindo que os valores usados pelo sistema refletem as características hidrológicas observadas e os critérios operacionais definidos.

AS04 – Métricas de Qualidade dos Dados(Quarentena)

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Percentagem de valores em falta (%), Número de valores anómalos detetados, Taxa de consistência entre fontes (%), Taxa de duplicação (%)

Granularidade Temporal: Diário, semanal e mensal

Dimensão Espacial: Fonte de Dados → Estação → Região

Objetivo: Permitir identificar problemas de qualidade nos dados ao longo do tempo, suportando processos de validação, limpeza e correção que reduzam o impacto de dados incorretos nas análises, alertas e previsões geradas pelo sistema.

Necessidade de Implementação: 5 - Crítica

Tabela 22: Requisito AS04

Descrição: Permite monitorizar continuamente a qualidade dos dados integrados no sistema, identificando valores em falta, inconsistências, duplicações e anomalias que possam comprometer análises, alertas ou modelos preditivos.

AS05 – Gestão de Perfis de Utilizador

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Número de utilizadores ativos por perfil, Número de alterações de permissões, Tentativas de acesso não autorizado

Granularidade Temporal: Diário e mensal

Dimensão Espacial: Sistema (global)

Objetivo: Permitir administrar utilizadores, perfis e permissões de acesso, garantindo que diferentes tipos de utilizadores possuem acesso apenas às funcionalidades e dados necessários às suas responsabilidades.

Necessidade de Implementação: 1 - Residual

Tabela 23: Requisito AS05

Descrição: Permite definir perfis de utilizador e controlar permissões de acesso às funcionalidades e dados do sistema, garantindo que cada utilizador apenas consegue visualizar ou modificar a informação autorizada.

AS06 – Auditoria de Acessos e Operações

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Número de acessos por utilizador, Número de operações realizadas (leitura/escrita), Logs de atividade por período, Eventos de segurança registados

Granularidade Temporal: Evento, diário, mensal

Dimensão Espacial: Utilizador → Sistema

Objetivo: Manter um registo completo, histórico e auditável de todas as interações com o sistema, garantindo rastreabilidade, suporte a auditorias de segurança e conformidade com políticas de governação de dados

Tipo de Requisito: Segurança / Auditoria

Necessidade de Implementação: 1 - Residual

Tabela 24: Requisito AS06

Descrição: Permite registar e consultar historicamente os acessos ao sistema e as operações realizadas pelos utilizadores, possibilitando rastrear atividades, investigar incidentes e verificar a utilização das funcionalidades disponíveis.

AS07 – Monitorização da Latência de Dados

Agente de Decisão: Administrador do Sistema

Indicadores / Métricas: Tempo entre ingestão e disponibilização (min) e Tempo de atualização por fonte

Granularidade Temporal: Tempo real, histórico diário

Dimensão Espacial: Fonte de Dados → Sistema

Objetivo: Permitir monitorizar se os dados estão a ser disponibilizados dentro dos tempos esperados de processamento e atualização, identificando atrasos que possam comprometer análises, alertas ou previsões operacionais.

Tipo de Requisito: Técnico

Necessidade de Implementação: 4 - Elevada

Tabela 25: Requisito AS07

Descrição: Permite monitorizar o tempo decorrido entre a recolha ou ingestão dos dados e a sua disponibilização para análise, identificando atrasos que possam comprometer a utilização de informação atualizada em cenários operacionais.

2.3. Análise e Validação Geral dos Requisitos

Concluída a fase de organização e documentação dos requisitos levantados, a equipa de desenvolvimento procedeu à sua análise e validação formal, com o objetivo de garantir que o conjunto de requisitos produzido é completo, consistente, não ambíguo e adequado às necessidades analíticas e operacionais dos agentes de decisão identificados. No contexto de sistemas de Data Warehousing, esta fase assume particular relevância, uma vez que os requisitos constituem a base para a definição da matriz de decisão, da granularidade dos dados (grain), das tabelas de factos e das dimensões do modelo dimensional. Assim, eventuais lacunas ou inconsistências nesta fase podem comprometer diretamente a qualidade da

modelação e, consequentemente, a capacidade do sistema em suportar corretamente os processos de análise e tomada de decisão.

O processo de validação adotado pela equipa assentou em duas atividades complementares: a análise cruzada interna dos requisitos e a validação externa junto dos representantes dos agentes de decisão. Esta abordagem permitiu assegurar simultaneamente o rigor técnico dos requisitos e o seu alinhamento com as necessidades reais do domínio de aplicação.

Análise cruzada interna. A análise cruzada dos requisitos levantados foi realizada através de sessões de trabalho internas da equipa de desenvolvimento, nas quais cada requisito foi sujeito a um conjunto estruturado de verificações, alinhadas com boas práticas de engenharia de requisitos e de modelação dimensional. Em primeiro lugar, foi avaliada a completude de cada requisito, garantindo que este inclui a identificação explícita das métricas e indicadores relevantes, bem como a sua granularidade temporal e espacial, elementos essenciais para a definição do nível de detalhe (grain) das futuras tabelas de factos. Em segundo lugar, foi verificada a consistência entre requisitos, tanto dentro do mesmo perfil de agente de decisão como entre perfis distintos, procurando identificar redundâncias, sobreposições ou contradições. Esta análise foi particularmente importante para assegurar a coerência das métricas e das dimensões partilhadas (conformed dimensions), fundamentais em sistemas de Data Warehousing. Adicionalmente, foi avaliada a clareza e não ambiguidade dos requisitos, garantindo que a sua formulação permite uma interpretação inequívoca por parte da equipa técnica responsável pela modelação e implementação. Por fim, foi analisada a adequação dos requisitos à modelação dimensional, verificando se cada requisito pode ser diretamente mapeado para elementos do modelo, nomeadamente:

- tabelas de factos (indicadores e métricas),
- dimensões analíticas (tempo, localização, entidade),
- e operações analíticas (agregação, comparação, análise temporal).

Validação externa. Após a análise cruzada interna, o conjunto de requisitos foi submetido a validação externa junto dos representantes dos agentes de decisão envolvidos no processo de levantamento, nomeadamente os perfis de analista hidrológico, responsável de proteção civil e decisor estratégico. Cada representante foi convidado a:

- confirmar a correção e relevância dos requisitos associados ao seu perfil,
- validar a completude das necessidades de informação identificadas,
- e assinalar eventuais omissões, imprecisões ou necessidades adicionais.

Este processo permitiu garantir que os requisitos refletem de forma fidedigna os processos reais de decisão e as necessidades operacionais do domínio, evitando desvios entre o sistema projetado e o sistema efetivamente necessário. As contribuições recolhidas foram analisadas pela equipa de desenvolvimento e incorporadas na versão final do catálogo de requisitos, sendo posteriormente sujeitas a uma nova verificação interna para garantir a manutenção da consistência global.

3. Modelação Dimensional de Dados

3.1. Apresentação da Abordagem Realizada

A modelação do armazém de dados segue a abordagem de modelação dimensional proposta por Kimball, adotando uma estratégia bottom-up, considerada adequada ao contexto da PreFlood e aos objetivos analíticos definidos no âmbito da monitorização e previsão de cheias. Esta abordagem privilegia a identificação de processos de negócio mensuráveis, nomeadamente a monitorização de variáveis meteorológicas e hidrológicas, bem como o registo de eventos de cheia, materializados em tabelas de factos, rodeadas por dimensões descritivas que fornecem o contexto necessário à análise, como o tempo, a localização, a estação de monitorização e a fonte de dados.

Contudo, a modelação não foi conduzida de forma linear nem exclusivamente dependente das fontes disponíveis. Pelo contrário, a equipa adotou uma abordagem iterativa em três níveis, destinada a separar claramente a perspetiva de negócio da perspetiva dos dados efetivamente acessíveis.

Num primeiro momento, foi construído um modelo dimensional ideal, derivado diretamente dos requisitos dos agentes de decisão. Este modelo representa a visão analítica desejável do sistema, sem considerar ainda restrições de disponibilidade, qualidade ou granularidade das fontes. A sua função é explicitar, de forma conceptual, quais seriam os factos, dimensões, hierarquias e atributos mais adequados para suportar integralmente os processos de decisão identificados.

Num segundo momento, foi definido um modelo obtido a partir das fontes de informação efetivamente disponíveis. Nesta fase, o modelo ideal foi confrontado com os dados recolhidos, identificando-se lacunas, atributos inexistentes, diferenças de granularidade temporal e espacial, bem como limitações de cobertura histórica. O objetivo desta etapa consistiu em perceber até que ponto os requisitos podiam ser satisfeitos com os dados realmente acessíveis.

Por fim, foi estabelecido o modelo implementado, correspondente à versão final operacionalizada no sistema. Este modelo resulta do ajustamento entre a necessidade analítica e a viabilidade técnica, integrando não apenas os atributos diretamente obtidos das fontes, mas também atributos derivados, transformados ou complementados por outras vias sempre que necessário. Em situações específicas, poderão mesmo ser considerados mecanismos de enriquecimento manual de certos dados, quando tal se revele indispensável para responder a requisitos críticos dos agentes de decisão.

Esta abordagem em três níveis permite documentar de forma rigorosa a evolução entre o que os decisores necessitam, o que as fontes permitem e o que é efetivamente implementado, reforçando a rastreabilidade metodológica do processo de modelação dimensional.




Figura 2: Modelo conceitual

3.2. A Matriz de Decisão

A matriz foi construída com base nas fontes IPMA, SNIRH e ER5-Land, com periodicidade horária, sabendo que as cheias podem ocorrer de um momento para outro, seja uma cheia repentina em fontes urbanas como a zona da Ribeira no Porto ou a acumulação da precipitação durante dias que pode provocar uma cheia do nível do rio.

Contém quatro dimensões principais: Tempo, Estações, Localização e Parâmetros. Estas dimensões foram escolhidas por permitirem análises críticas como “Qual a correlação entre a precipitação atual e a subida repentina do caudal?”

Datamart Hidrometeorológico — PreFlood_DW	
Identificação	Data Lakehouse para Prevenção de Cheias na Bacia do Rio Mondego
Descrição Geral	Sistema de suporte à decisão para prevenção e resposta a cheias na bacia hidrográfica do Mondego, integrando dados de sensores hidrológicos (SNIRH), meteorológicos (IPMA) e climáticos (ERA5).
Tabelas de Facto	fact_medicao
Dimensões	- dim_tempo - dim_estacao - dim_parametro - dim_bacia
Cardinalidade Dimensional	4 dimensões + 1 facto
Natureza	Híbrida — Data Lakehouse relacional (Bronze/Silver/Gold) + Data Mart de Machine Learning (ml.*) + camada de controlo (ctl.*)
Granularidade Temporal	Horária
Esquemas	brz (Bronze), silver (Silver), gold (Gold/Star), logs (ETL), ml (Data Mart ML), quarentena (rejeitados), ctl (controlo)
Fontes de Dados	- IPMA — observações meteorológicas em near-real-time (precipitação, temperatura, humidade, vento, pressão, radiação) - SNIRH — dados hidrológicos históricos (16 anos: nível instantâneo, cota de albufeira, caudal médio diário) - ERA5-Land — reanálise climática por grelha (precipitação total, temperatura 2m, saturação do solo L1–L4, pressão superficial)
Data Mart de ML	- Clustering: KMeans, HDBSCAN, IsolationForest - Previsão: LightGBM - Classificação: LSTM binário - Risco: classificação percentilar (BAIXO/MODERADO/ALTO/CRÍTICO) - Eventos: 584 cheias catalogadas
Descrição Operacional	Pipeline ETL SSIS com carga Bronze → Silver → Gold, seguido de pipeline ML de treino e previsão.
Objetivo Estratégico	- Antecipação de cheias com horizontes de 1h a 24h - Identificação de zonas e estações de vulnerabilidade - Suporte ao ordenamento do território via análise de tendências climáticas
Perfis de Utilizador	- Analista Hidrológico (AH) — consulta de medições, percentis, eventos, saturação do solo - Responsável de Protecção Civil (RPC) — avaliação de risco, alertas, probabilidade LSTM, painel integrado - Decisor Estratégico (DE) — evolução histórica, comparação entre estações, tendências climáticas - Administrador do Sistema (AS) — monitorização ETL, limiares, qualidade de dados, latência

Os agentes de decisão assumem papéis complementares. O Analista Hidrológico e o Administrador do Sistema, focados na vertente técnica e operacional, utilizam o sistema para validar a saúde das infraestruturas e interpretar o comportamento dos fluxos de água. Já o Responsável de Protecção Civil, focado na gestão de crise, apoia-se nos alertas de curto prazo para coordenar operações no terreno. Por fim, o Decisor Estratégico foca-se na evolução de longo prazo e planeamento de resiliência.

A matriz de decisão assegura que todos os perfis tenham acesso às informações relevantes para realizarem o seu trabalho.

3.3. Definição e Caracterização de Dimensões

O Data Mart Hidrometeorológico assenta em quatro dimensões centrais para qualificar os factos monitorizados.

Caracterização de Dimensão							
Identificação	dim_tempo						
Descrição	Calendário com 14 atributos temporais (granulação horária)						
Tipo	Normal						
Dimensão	Aproximadamente 175 200 registos (20 anos × 365 × 24)						
Crescimento	Cresce anualmente no máximo 366 × 24 = 8 784 registos						
Atributos							
Nr	Identificação	Descrição	Chave	Tipo dados	V/H/P	Var.	Exemplos
1	tempo_sk	Surrogate Key sequencial	S	Int (IDENTITY)			1, 2, 3, ...
2	data_hora	Data e hora exacta	N/U	Datetime2			2026-01-01 15:00:00
3	data	Data civil	N	Date			2026-01-01
4	hora	Hora do dia (0–23)	N	Int			15
5	ano	Ano	N	Smallint			2026
6	mes	Mês (1–12)	N	Tinyint			1
7	dia	Dia do mês (1–31)	N	Tinyint			31
8	trimestre	Trimestre (1–4)	N	Tinyint			4
9	semana_ano	Semana do ano (1–53)	N	Tinyint			52
10	dia_ano	Dia sequencial do ano (1–366)	N	Smallint			365
11	dia_semana	Dia da semana (1=Dom–7=Sáb)	N	Tinyint			4
12	dia_semana_nome	Nome do dia da semana	N	Nvarchar(20)			Quinta-feira
13	fim_de_semana	É fim de semana?	N	Bit			0
14	estacao_do_ano	Estação climática	N	Nvarchar(20)			Inverno

Tabela 26: Caracterização de Dimensão — dim_tempo

Nr	Identificação	Esquema
1	H1	tempo_sk → dia → mes → trimestre → ano

Tabela 27: Hierarquias — dim_tempo

Caracterização de Dimensão							
Identificação	dim_estacao						
Descrição	Identificação e caracterização das 244 estações de monitorização (IPMA, SNIRH, ERA5), com localização geográfica e estado de activação						
Tipo	Normal (SCD1 via MERGE)						
Dimensão	Aproximadamente 244 registos (222 IPMA + 14 SNIRH + 8 ERA5)						
Crescimento	Estável — novas estações apenas por configuração manual						
Atributos							
Nr	Identificação	Descrição	Chave	Tipo dados	V/H/P	Var.	Exemplos
1	estacao_sk	Surrogate Key sequencial	S	Int (IDENTITY)			1, 2, 3, ...
2	estacao_id	ID original da estação na fonte	N	Varchar(50)			12M/01G
3	estacao_nome	Nome da estação	N	Nvarchar(200)			Coimbra / Ben-canta
4	sistema_origem	Sistema de origem dos dados	N	Varchar(20)			IPMA, SNIRH, ERA5
5	latitude	Latitude (graus decimais)	N	Float			40.203
6	longitude	Longitude (graus decimais)	N	Float			−8.419
7	bacia_codigo	FK para dim_bacia	N/F	Bigint			47
8	ativa	Estação activa?	N	Bit			1
9	data_criacao	Timestamp de inserção	N	Datetime2			2026-01-15 10:30:00

Tabela 28: Caracterização de Dimensão — dim_estacao

Caracterização de Dimensão							
Identificação	dim_bacia						
Descrição	Dimensão de referência geográfica com o código e nome da bacia hidrográfica do Mondego						
Tipo	Normal						
Dimensão	1 registo (bacia do Mondego, código 47)						
Crescimento	Estática — apenas por configuração manual						
Atributos							
Nr	Identificação	Descrição	Chave	Tipo dados	V/H/P	Var.	Exemplos
1	bacia_codigo	Código oficial da bacia hidrográfica	S/PK	Bigint			47
2	bacia_nome	Nome da bacia hidrográfica	N	Nvarchar(100)			Bacia do Mondego

Tabela 29: Caracterização de Dimensão — dim_bacia

Caracterização de Dimensão							
Identificação	dim_parametro						
Descrição	Catálogo das 31 variáveis físicas medidas, com unidade, categoria e sistema de origem						
Tipo	Normal						
Dimensão	Aproximadamente 31 registos (parâmetros de IPMA, SNIRH e ERA5)						
Crescimento	Estável — novos parâmetros apenas por configuração manual						
Atributos							
Nr	Identificação	Descrição	Chave	Tipo dados	V/H/P	Var.	Exemplos
1	parametro_sk	Surrogate Key sequencial	S	Int (IDENTITY)			1, 2, 3, ...
2	parametro_id	ID numérico do parâmetro na fonte	N	Int			1843, 1850, 1
3	parametro_nome	Nome descritivo do parâmetro	N	Nvarchar(200)			Nível Instantâneo
4	parametro_codigo	Código usado em queries e scripts ML	N	Varchar(50)			1843, prec, swvl1
5	categoria	Categoria do parâmetro	N	Nvarchar(50)			Hidrológico, Meteorológico
6	unidade_medida	Unidade de medida	N	Nvarchar(30)			m, mm, m³/s, %, °C
7	sistema_origem	Sistema de origem	N	Varchar(20)			IPMA, SNIRH, ERA5
8	granularidade	Granularidade temporal do parâmetro	N	Varchar(20)			horária, diária

Tabela 30: Caracterização de Dimensão — dim_parametro

3.4. Definição e Caracterização da Tabela de Factos

A definição da tabela de factos resultou da análise dos requisitos analíticos identificados para os quatro perfis de utilizador do sistema. O objectivo é permitir a análise temporal e espacial dos fenómenos hidro-meteorológicos, suportando simultaneamente a monitorização operacional e a construção de modelos preditivos.

3.4.1. Escolha do Modelo

A partir da análise dos requisitos de negócio e da matriz de decisão elaborada, foi definida uma única tabela de factos, designada fact_medicao, responsável por armazenar todas as observações hidrológicas e meteorológicas recolhidas pelas três fontes de dados do sistema (IPMA, SNIRH, ERA5).

Esta abordagem centraliza num único repositório as medições provenientes de estações meteorológicas, hidrométricas e de reanálise climática, garantindo consistência na análise e facilitando a comparação entre diferentes parâmetros ao longo do tempo e entre fontes de dados distintas.

3.4.2. Grão da Tabela de Factos

O grão foi definido como: **uma medição de um determinado parâmetro, recolhida numa estação específica, numa determinada hora.**

Significa que cada linha na tabela de factos representa o valor observado de um único parâmetro (ex: precipitação, nível instantâneo, temperatura), numa estação de monitorização concreta, num instante temporal com granularidade horária.

3.4.3. Granularidade Temporal

A granularidade temporal foi definida ao nível da hora. Os fenómenos de cheia, particularmente as cheias rápidas (*flash floods*), caracterizam-se por uma evolução muito acelerada. Períodos de precipitação intensa podem provocar aumentos significativos dos níveis dos rios e caudais num intervalo de apenas algumas horas. A utilização de uma granularidade horária permite:

- Capturar estas variações com a precisão necessária para a deteção precoce;
- Preservar a dinâmica temporal do fenómeno;
- Suportar o treino de modelos preditivos com horizontes de 1h a 24h;
- Alinhar dados de fontes com periodicidades distintas (SNIRH horário, IPMA horário, ERA5 horário).

3.4.4. Medidas

A tabela de factos contém as seguintes medidas:

Medida	Descrição	Tipo	Agregações
valor	Valor observado para o parâmetro monitorizado (m, mm, °C, %, m³/s, etc.)	Contínua	Semi-agregável: aditiva por estação e parâmetro (SUM para precipitação, AVG para níveis/temperaturas), mas a agregação no tempo depende da natureza do parâmetro
data_ingestao	Momento em que o registo foi integrado no sistema (metadata ETL)	Timestamp	Não agregável — metadado de controlo ETL, sem significado analítico

3.5. Configuração dos Esquemas

A organização do armazém de dados foi concebida segundo uma arquitetura *Data Lakehouse* e com um *Data Mart* específico para *Machine Learning*.

O sistema foi estruturado em torno de um Data Mart Hidrometeorológico, destinado a suportar os processos de monitorização, análise histórica e previsão de cheias. Este Data Mart concentra na camada Gold toda a informação necessária à análise dos fenómenos hidrológicos e meteorológicos observados na bacia hidrográfica do Mondego.

As quatro dimensões definidas são:

- **dim_tempo** — responsável pela análise temporal das medições, permitindo agregações por hora, dia, semana, mês, trimestre e ano, bem como filtros por estação do ano e fim de semana;
- **dim_estacao** — caracteriza as 244 estações de monitorização das três fontes (IPMA, SNIRH, ERA5), com localização geográfica (lat/lon) e estado de activação;
- **dim_bacia** — permite a análise por bacia hidrográfica (código 47 — Mondego);
- **dim_parametro** — identifica as 31 variáveis observadas, organizadas por categoria (Meteorológica, Hidrológica, Climática), incluindo precipitação, temperatura, humidade, pressão, velocidade e direcção

do vento, radiação solar, nível instantâneo, caudal médio diário, cota de albufeira e saturação do solo (L1–L4).

3.6. Vistas dos Agentes de Decisão

O armazém de dados foi concebido para suportar quatro perfis de utilizador, cada um com necessidades específicas de análise e tomada de decisão. Embora todos os agentes acedam à mesma base de informação, as suas vistas diferem em termos de granularidade, nível de agregação e indicadores consultados.

3.6.1. Analista Hidrológico (AH)

O Analista Hidrológico necessita de acesso ao maior nível de detalhe disponível no sistema, sendo responsável pela monitorização contínua das condições hidrológicas e meteorológicas.

A sua vista é construída directamente sobre a tabela de factos, permitindo:

- Analisar a evolução horária da precipitação, dos níveis dos rios e dos caudais;
- Comparar valores actuais com percentis históricos (P50–P99);
- Consultar o catálogo de eventos de cheia históricos (584 eventos);
- Monitorizar a saturação do solo via ERA5 (swvl1–swvl4);
- Correlacionar precipitação com níveis hidrológicos via proximidade espacial;
- Visualizar a distribuição geográfica das estações;
- Exportar dados para análise externa.

Requisitos cobertos: AH01–AH09 (9 requisitos).

3.6.2. Responsável de Protecção Civil (RPC)

O Responsável de Protecção Civil necessita de informação operacional para apoiar a gestão de emergências e a activação de planos de contingência.

A sua vista privilegia indicadores agregados e alertas operacionais, permitindo:

- Avaliar o nível de risco por estação (BAIXO a CRÍTICO, 5 níveis);
- Consultar alertas automáticos (WARNING/ALERT/CRITICAL);
- Conhecer a probabilidade de cheia via LSTM (horizontes 6h, 12h, 24h);
- Visualizar o painel integrado de risco com predições a 5 horizontes;
- Consultar previsões de nível hidrométrico via LightGBM (1h–24h).

Requisitos cobertos: RPC01–RPC05 (5 requisitos).

3.6.3. Decisor Estratégico (DE)

O Decisor Estratégico utiliza o sistema para suportar decisões de médio e longo prazo relacionadas com a gestão do risco hídrico.

A sua vista apresenta informação fortemente agregada, permitindo:

- Analisar a evolução histórica de eventos de cheia por ano;
- Comparar o risco entre estações da bacia;
- Avaliar a severidade de cada evento (pré/pós-análise);
- Identificar tendências climáticas de longo prazo.

Requisitos cobertos: DE01–DE04 (4 requisitos).

3.6.4. Administrador do Sistema (AS)

O Administrador do Sistema é responsável pela supervisão da qualidade e disponibilidade dos dados armazenados.

A sua vista está orientada para aspectos técnicos do sistema, permitindo:

- Monitorizar o estado das fontes de dados e a latência;
- Consultar o histórico de execuções ETL;
- Gerir limiares e modelos treinados;
- Monitorizar registos rejeitados (quarentena);

Requisitos cobertos: AS01–AS07 (7 requisitos).

4. Arquitetura Geral do Sistema

4.1. Apresentação Geral

Este *Data Lakehouse* foi desenvolvido em SQL Server para a prevenção e resposta a cheias na bacia hidrográfica do rio Mondego. A arquitectura segue uma abordagem por camadas (Bronze → Silver → Gold), complementada por um *Data Mart* de *Machine Learning*.

A solução integra dados de três fontes heterogéneas: observações meteorológicas em tempo real do IPMA, dados hidrológicos históricos do SNIRH e reanálise climática do ERA5-Land.

Permite criar assim, um repositório unificado que suporta simultaneamente a análise multidimensional, a modelação preditiva e a emissão de alertas.

4.2. Fontes de Dados

O sistema integra dados de três fontes heterogéneas, cada uma com características distintas de periodicidade, cobertura geográfica e tipo de parâmetros recolhidos. A integração destas fontes num único repositório permite uma visão holística do estado hidrometeorológico da bacia do Mondego.

4.2.1. IPMA — Instituto Português do Mar e da Atmosfera

Parâmetro	Valor
Tipo	Observações meteorológicas em tempo real
Cobertura geográfica	222 estações meteorológicas em Portugal continental, filtradas para a região da bacia do Mondego
Granularidade temporal	Horária
Profundidade histórica	Variável (dados correntes, sem histórico profundo)
Acesso	API REST pública (<code>api.ipma.pt</code>)
Parâmetros recolhidos	Temperatura, humidade, pressão atmosférica, velocidade do vento (km/h e m/s), direcção do vento, precipitação, radiação solar
Bronze	<code>brz.ipma_obs</code> (18 219 registos), <code>brz.ipma_est</code> (888 registos)
Silver	<code>silver.ipma_observations</code> , <code>silver.ipma_stations</code>
Tipo de ingestão	Script Task no SSIS — chamada HTTP à API, deserialização JSON, escrita directa em <code>brz</code>

4.2.2. SNIRH — Sistema Nacional de Informação de Recursos Hídricos

Parâmetro	Valor
Tipo	Observações hidrológicas históricas
Cobertura geográfica	14 estações hidrométricas na bacia do Mondego (bacia_codigo=47); 4 estações naturais (rios) + 7 barragens + 3 estações complementares
Granularidade temporal	Horária (nível instantâneo) e diária (caudal médio)
Profundidade histórica	16 anos (aproximadamente 2010–2026) este volume de dados serve mais para ML, será usado um valor reduzido para efeitos de demonstração
Acesso	Web scraping do portal SNIRH (APA)
Parâmetros recolhidos	Nível instantâneo (código 1843), caudal médio diário (código 1850), cota de albufeira
Bronze	brz.snirh_obs (683 844 registos), brz.snirh_est (14 registos)
Silver	silver.snirh_observations, silver.snirh_stations
Tipo de ingestão	Script Task no SSIS, extracção de 16 anos de dados por estação e parâmetro
Estações-chave	Naturais: SK 229, 232, 233, 234 Barragens: SK 223–226, 228, 230, 235
Observações	Fonte principal para o cálculo de risco — os limiares percentilares (P50–P99) e as labels de cheia são calculados exclusivamente sobre dados SNIRH.

4.2.3. ERA5-Land — Reanálise Climática do Copernicus

Parâmetro	Valor
Tipo	Reanálise climática por grelha (dados modelados, não observações directas)
Cobertura geográfica	8 células de grelha com coordenadas múltiplas de 0.1° sobre a bacia do Mondego
Granularidade temporal	Horária
Profundidade histórica	16+ anos (aproximadamente 1950–presente, com acesso via CDS API)
Acesso	CDS API (Copernicus Climate Data Store) — download em batch de ficheiros NetCDF
Parâmetros recolhidos	Temperatura a 2m, precipitação total, pressão superficial, saturação do solo (volumetric soil water levels 1–4)
Bronze	brz.era5_obs (1 120 896 registos)
Silver	silver.era5_observations, silver.era5_locations
Tipo de ingestão	Execute Process Task no SSIS — script Python bronze_era5.py com download via CDS API, descompressão ZIP, parse de ficheiros NetCDF e escrita em brz
Restrições técnicas	Lat/lon devem ser múltiplos de 0.1 (requerimento CDS API). Precipitação negativa clampada a 0 na transformação Silver
Observações	Fornece cobertura espacial uniforme onde não existem estações físicas. Essencial para o cálculo de saturação do solo e precipitação antecedente nos modelos ML. Os 708 mapeamentos de proximidade espacial (KDTree) ligam estações IPMA/SNIRH às células ERA5 mais próximas.

4.2.4. Configuração para usar o pipeline

Além das dependências python mencionadas no tópico 1.5 do projeto deverá ser mudados alguns ficheiros como:

- ST_BronzeIPMA.cs, a pasta de landing
- ST_BronzeSNIRH.cs, a pasta de landing
- ST_BronzeERA5.cs, a pasta de landing
- Credenciais do copernicus climate data store (deve criar o ficheiro .cdsapirc na pasta pessoal do utilizador que executa o SSIS (ex: C:\Users\{utilizador}\.cdsapirc) com o seguinte conteúdo:

```
url: https://cds.climate.copernicus.eu/api/v2
key: {UID}:{API-KEY}
```

A razão por termos variáveis de ambiente como fixas no código que apesar de ser uma má prática e desaconselhado foi de termos dificuldades ao usar variáveis ao nível do projeto dentro do SSIS e até porque surgiram algumas condições de race condition quando o pipeline estava em paralelo.

4.3. Área de Preparação de Dados

Usamos um Datalakehouse em que a preparação de dados segue esquemas internos: Bronze (brz) e Silver (silver), que funcionam como área de preparação progressiva, onde os dados são ingeridos, validados e transformados antes de alimentar o esquema da camada Gold.

Esta abordagem foi escolhida por três razões principais. Primeiro, centraliza todos os dados num único repositório, eliminando a necessidade de manter e sincronizar múltiplos sistemas. Segundo, preserva a rastreabilidade completa, cada registo mantém o ficheiro de origem (_arquivo), o identificador de execução (_run_id) e o momento de carga (_dt_carga).

4.3.1. Camada Bronze

A camada Bronze funciona como a primeira área de recepção de dados. O seu propósito é armazenar os dados exactamente como chegam das fontes, sem qualquer transformação ou validação, garantindo que nenhuma informação se perde durante o processo de ingestão.

Todos os campos das tabelas Bronze são do tipo NVARCHAR, independentemente do tipo de dados original. Esta decisão é deliberada: permite ingerir dados de fontes heterogéneas sem risco de erros de conversão durante a carga inicial. Se um valor de temperatura contiver texto inesperado ou um campo numérico estiver vazio, o registo é aceite na mesma, sendo os problemas de qualidade identificados e tratados na fase seguinte.

Cada tabela Bronze inclui três colunas de auditoria: _arquivo (caminho do ficheiro ou URL de origem), _run_id (identificador único da execução ETL) e _dt_carga (timestamp de inserção). Estas colunas permitem rastrear qualquer registo até à execução específica que o carregou e ao ficheiro original.

As cinco tabelas Bronze organizam-se por fonte: brz.ipma_obs e brz.ipma_est para observações e estações meteorológicas do IPMA; brz.snirh_obs e brz.snirh_est para dados hidrológicos do SNIRH; e brz.era5_obs para a reanálise climática do Copernicus. A separação por fonte permite aplicar regras de qualidade distintas durante a transformação para Silver, adaptadas às características de cada sistema.

O processo de carga Bronze é realizado por três Script Tasks no SSIS, cada um especializado numa fonte: o Script Task IPMA faz download via API REST e parse de JSON; o Script Task SNIRH faz web scraping do portal da APA; o Script Task ERA5 invoca um script Python que utiliza a CDS API do Copernicus. Em todos os casos, os dados são escritos directamente nas tabelas Bronze.

4.3.2. Camada Silver — Validação e Tipagem

A camada Silver constitui a verdadeira área de preparação onde os dados são limpos, validados e convertidos para os seus tipos nativos. É aqui que ocorre a transformação de NVARCHAR para FLOAT, DATETIME2, INT e outros tipos correctos, com rejeição dos registos que não passam nas regras de qualidade.

O processo de transformação Bronze→Silver aplica as seguintes operações:

Conversão de tipos: Os valores NVARCHAR são convertidos para FLOAT usando TRY_CAST, que retorna NULL para valores inválidos em vez de gerar erros. As datas são convertidas com TRY_CAST para DATETIME2, com tratamento de formatos específicos (como o separador T do IPMA).

Deduplicação: A carga Silver utiliza MERGE para estações (actualizando registos existentes) e INSERT...WHERE NOT EXISTS para observações (inserindo apenas registos novos). Isto permite execuções repetidas do pipeline sem duplicar dados.

Validação de qualidade: Valores sentinela (como -99 no IPMA, que segundo a sua documentação indica dados em falta) são rejeitados. Registos com datas inválidas ou identificadores vazios são encaminhados para a tabela quarentena. ETL_Quarentena, que armazena o registo original em JSON, o motivo da rejeição e um flag de resolução.

Normalização: A tabela Silver separa as estações das observações (ao contrário do Bronze, onde tudo fica numa única tabela por fonte). As estações recebem bacia_codigo=47 como valor por omissão. Os parâmetros são mapeados para IDs numéricos padronizados.

Inputar valores: Dados ERA5 com precipitação negativa (artefacto do modelo de reanálise) são inputados a 0 em vez de rejeitados, pois são tecnicamente válidos mas fisicamente impossíveis.

As seis tabelas Silver organizam-se em pares por fonte: silver.ipma_stations + silver.ipma_observations para o IPMA; silver.snirh_stations + silver.snirh_observations para o SNIRH; silver.era5_locations + silver.era5_observations para o ERA5. Cada par tem chaves primárias compostas que garantem unicidade por timestamp, estação e parâmetro.

4.3.3. Fluxo de Dados Através das Camadas

O fluxo de dados segue um percurso unidireccional que garante isolamento entre as camadas:

Os dados entram pela camada Bronze, onde são armazenados no formato original. De seguida, são transformados e validados para a camada Silver, onde adquirirão tipos correctos e qualidade controlada. Finalmente, são carregados para a camada Gold, onde alimentam o esquema estrela (dimensões e facto). Paralelamente, os registos rejeitados são encaminhados para a quarentena, e todas as operações são registadas no schema de logging.

Este fluxo garante que a camada Gold nunca é carregada directamente a partir de dados brutos.

Todo o dado passa obrigatoriamente pela validação Silver antes de estar disponível para análise. Ao mesmo tempo, a camada Bronze preserva os dados originais, permitindo reprocessamento caso as regras de qualidade ou negócio mudem.

4.4. Exploração e Visualização de Dados

O sistema de visualização do PreFlood_DW é construído sobre o Microsoft Power BI, que se liga directamente ao armazém de dados SQL Server.

4.4.1. Modo de acesso

O Power BI conecta-se ao SQL Server utilizando autenticação Windows (Trusted_Connection), acedendo directamente à base de dados PreFlood_DW

Para a interface web é necessário ler o README.md iniciar o servidor e usar as respetivas credenciais.

4.4.2. Vistas do Sistema e Dashboards por Perfil

No PowerBi foi criado os seguintes dashboards, sendo cada página um perfil de utilizador excluido o administrador do sistema:




Figura 3: Página 2




Figura 4: Página 2




Figura 5: Página 3

Foram também criados alguns dashboards web:

Para Analista Hidrológico:




Figura 6: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego




Figura 7: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego




Figura 8: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego




Figura 9: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego

Para Responsável de Proteção Civil:




Figura 10: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego

Para Decisor Estratégico:




Figura 11: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego




Figura 12: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego

Para Administrador do Sistema:

Preflood DW		Administrador do Sistema						
Dashboard		Estado das Fontes de Dados						
Administrador Sistema		Fonte	Tabela	Estado	Lidos	Escritos	Rejeitados	Erros
Fontes de Dados		EXTRACAO->API->Bronze ERAS	ERAS	Atualizado	1120896	1120896	0	0
Historico ETL		EXTRACAO->API->Bronze IPMA	IPMA	Atualizado	19107	19107	0	0
Limpeza		EXTRACAO->API->Bronze SNIRH	SNIRH	Atualizado	683858	683858	0	0
Quarentena		LOAD->Load Dim Estacao	Load Dim Estacao	Atualizado	—	—	—	0
Latencia		LOAD->Load Dim Tempo	Load Dim Tempo	Atualizado	—	—	—	0
Modelos ML		LOAD->Load Fact Medicao	Load Fact Medicao	Atualizado	—	—	—	0
Terminar Sessão		TRANSFORM->Bronze->Silver ERAS Locations	ERAS Locations	Atualizado	1120896	8	1120888	0
		TRANSFORM->Bronze->Silver ERAS Observations	ERAS Observations	Atualizado	1120896	1102874	18022	0
		TRANSFORM->Bronze->Silver IPMA Observations	IPMA Observations	Atualizado	4557	15763	11206	0
		TRANSFORM->Bronze->Silver IPMA Stations	IPMA Stations	Atualizado	222	222	0	0
		TRANSFORM->Bronze->Silver SNIRH Observations	SNIRH Observations	Atualizado	683844	683844	0	0
		TRANSFORM->Bronze->Silver SNIRH Stations	SNIRH Stations	Atualizado	14	14	0	0

Figura 13: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego

Segue no diretório do projeto entregue também um Jupyter Notebook com a respetiva parte de ML sendo possível analisar alguns gráficos no **Anexo 1**.

4.5. Aquisição de Conhecimento

Para adquirir conhecimento foi transformado os dados validados do esquema Silver em conhecimento accionável, através de processos de caracterização e modelação preditiva. Este sistema opera sobre a estrela do esquema Gold e produz resultados armazenados no esquema ML, cobrindo todo o pipeline desde a engenharia de features até à emissão de alertas de risco.

4.5.1. Architectura do Pipeline ML

O pipeline de aquisição de conhecimento é composto por 9 scripts Python que executam sequencialmente em 3 fases. A Fase 1 (Caracterização) engloba a construção da proximidade espacial e a rotulagem de eventos de cheia. A Fase 2 (Modelação) inclui o clustering, as previsões de nível por LightGBM e a classificação de cheia por LSTM. A Fase 3 (Operacionalização) engloba a predição em tempo real, o catálogo de eventos históricos, o motor de alerta precoce e a actualização com dados reais.

Todos os scripts partilham a configuração centralizada em `preflood_config.py`, que define a ligação à base de dados e os directórios de trabalho. Os modelos treinados são persistidos em ficheiros no directório `Models/`: 25 modelos `.lgb` (LightGBM) 5 deles globais 1 por horizonte temporal (1h,3h,6h,12h,24h) e 20 deles locais por estação e também 5 horizontes, 3 modelos `.keras` (LSTM) para (6h,12h,24h) e 2 ficheiros de features `.pkl`. Esta abordagem permite que o sistema faça inferência sem re-treinar os modelos a cada execução.

4.5.2. Fase 1 — Caracterização

A caracterização é o processo que prepara os dados do esquema Gold para consumo pelos algoritmos de aprendizagem automática, criando variáveis derivadas e etiquetas que não existem nos dados observacionais.

Proximidade Espacial (`build_spatial_proximity.py`): Este script calcula 708 mapeamentos de proximidade entre as estações de medição e as células de reanálise ERA5, utilizando a fórmula de Haversine para distâncias geodésicas. Os 222 estações IPMA são mapeadas às células ERA5 mais próximas, e as 14 estações SNIRH são mapeadas igualmente. Para cada mapeamento, o script regista a distância em quilómetros e

o rank de proximidade. O resultado é armazenado em `ml.spatial_proximity` e utilizado por todos os modelos subsequentes para alinhar as observações com os dados de reanálise.

Rotulagem de Eventos de Cheia (`flood_labeling.py`): Este script gera 375 834 etiquetas binárias de cheia para as 4 estações naturais do SNIRH (SK 229, 232, 233, 234), utilizando o percentil 95 do nível hidrométrico histórico como limiar. Para cada observação, são calculadas 3 etiquetas com horizontes de previsão distintos: `flood_6h` (cheia nas próximas 6 horas), `flood_12h` (12 horas) e `flood_24h` (24 horas). O resultado é uma taxa de positivos pequena, reflectindo o desequilíbrio natural da classe minoritária. As etiquetas são armazenadas em `ml.flood_labels` e servem como variável alvo para o modelo LSTM.

4.5.3. Fase 2 — Modelação Preditiva

A modelação preditiva executa em paralelo dois modelos complementares: o LightGBM para regressão (previsão do nível hidrométrico em valores contínuos) e o LSTM para classificação binária (probabilidade de ocorrência de cheia). Esta dualidade permite que o sistema forneça simultaneamente uma quantificação do nível esperado e uma probabilidade de evento extremo, informação que é complementar para a tomada de decisão.

Clustering e Detecção de Anomalias (`flood_ml.py`): Este script aplica três algoritmos não supervisionados sobre os dados do esquema Gold para identificar padrões e anomalias. O KMeans com $k=5$ segmenta as observações em 5 clusters de comportamento hidrometeorológico. O HDBSCAN identifica grupos densos de pontos atípicos. O IsolationForest detecta anomalias globais com base em 16 features construídas a partir das medições (precipitação acumulada, nível actual, saturação do solo, gradiente temporal). Os resultados são armazenados em `ml.results`.

Previsão de Nível — LightGBM (`forecast_ml.py`): Este script treina 25 modelos LightGBM de regressão para prever o nível hidrométrico com horizontes de 1, 3, 6, 12 e 24 horas. É treinado um modelo global (todas as estações) e 24 modelos por estação, utilizando features de lag (nível e precipitação nas últimas 1h, 3h, 6h, 12h, 24h, 48h, 72h), features de agregação (média, máximo, desvio padrão em janelas móveis), features de calendário (hora, dia, mês, estação do ano), e features ERA5 (precipitação acumulada, temperatura, pressão, saturação do solo). O desempenho varia de $R^2=0,9972$ para 1h (quase perfeito) até $R^2=0,9754$ para 24h (excelente), demonstrando que o sinal hidrológico é altamente predictível nestes horizontes. Tal permite concluir também que para intervalos mais pequenos de tempo sabendo o nível actual é muito mais fácil prever. Os modelos são persistidos como ficheiros `.lgb` e as previsões históricas armazenadas em `ml.forecast_predictions`.

Classificação de Cheia — LSTM (`lstm_flood.py`): Este script treina 3 redes neurais recorrentes LSTM para classificação binária de cheia, essas labels são calculadas com o percentil 95 do nível hidrométrico histórico de cada estação natural, usando dados com horizontes de 6h, 12h e 24h. A arquitectura de cada modelo consiste numa camada LSTM com 128 unidades, seguida de Dropout(0,3), uma segunda camada LSTM com 64 unidades, Dropout(0,2), e uma camada Dense com activação sigmoid. A entrada é uma sequência de 24 horas com 16 features por timestep, construídas com janelas deslizantes sobre os dados do esquema Gold. O treino utiliza TensorFlow em modo CPU, com class weights para compensar o desequilíbrio de classes, EarlyStopping com paciência=10, e optimizador Adam. O desempenho atinge AUC de 0,84 para 6h e 0,78 para 24h, valores considerados bons para classificação de eventos raros. Os modelos são persistidos como ficheiros `.keras` e as métricas de treino registadas em `ml.model_registry`.

4.5.4. Fase 3 — Operacionalização

A operacionalização transforma os modelos treinados num sistema de alerta funcional, capaz de gerar previsões em tempo real e detectar eventos de cheia com antecedência.

Predição em Tempo Real (`predict_now.py`): Este script carrega os modelos LightGBM treinados e aplica-os aos dados mais recentes do esquema Gold, gerando previsões de nível hidrométrico para as 4 estações naturais em 5 horizontes (1h, 3h, 6h, 12h, 24h). Para cada estação, o script recolhe as últimas 400 horas de observações SNIRH (nível e caudal de todas as estações, naturais e de albufeira), 35 dias de dados ERA5, e 30 horas de observações IPMA, construindo o mesmo vector de features utilizado no treino. As previsões são armazenadas em `ml.predictions_now` e incluem o valor previsto, a data de referência e o horizonte.

Foram seleccionadas apenas as estações naturais como alvo preditivo — as estações de albufeira (SK 223–226, 228, 230, 235) medem cotas de armazenamento cujo nível é determinado majoritariamente pela gestão humana (abertura de comportas, turbinagem, descargas), apresentando padrões contraditórios com as condições hidrometeorológicas. As albufeiras participam indirectamente como variáveis preditivas de montante: os níveis e caudais das barragens são incluídos como features de lag, capturando o efeito regulador que exercem sobre o regime hidrológico a jusante.

Catálogo de Eventos Históricos (`compute_flood_events.py`): Este script analisa retrospectivamente os 8,35 milhões de registos para identificar e catalogar 584 eventos de cheia distintos. Para cada evento, são calculados a duração, o pico de nível, a severidade (baseada na duração do excedimento), a velocidade de subida e as condições antecedentes (precipitação acumulada em 24h/48h/72h, saturação do solo). Os resultados são armazenados em `ml.ew_flood_events` e utilizados pelo motor de alerta como referência histórica.

Motor de Alerta Precoce (`early_warning.py`): Este script implementa um sistema de alerta de 3 camadas que avalia o risco actual de cheia. A Camada 1 (Observação) compara os valores actuais com os limiares de alerta armazenados em `ctl.ew_thresholds`. A Camada 2 (Previsão) verifica se as previsões LightGBM ultrapassam os limiares nos próximos horizontes temporais. A Camada 3 (Probabilidade) avalia a probabilidade LSTM de cheia. As detecções são armazenadas em `ml.ew_detections` com classificação de camada, nível de risco e qualidade do lead time, e o seu accionamento gera alertas em `gold.alertas` via `ctl.usp_evaluate_alerts`.

Actualização com Dados Reais (`update_actuals.py`): Este script compara as previsões anteriores com os valores observados entretanto disponíveis, marcando como verificados ou pendente cada previsão. As previsões pendentes representam horizontes temporais que ainda não foram atingidos, sendo o comportamento esperado do sistema.

5. O Povoamento de Dados

5.1. Apresentação da Abordagem Realizada

O processo de integração de dados do PreFlood_DW segue a metodologia Data Lakehouse com arquitetura medallion de 3 camadas (Bronze–Silver–Gold), implementada sobre SQL Server 2025 e orquestrada por SQL Server Integration Services (SSIS). A notação utilizada para modelação do pipeline é BPMN (Business Process Model and Notation), que permite representar visualmente as tarefas, sequências, paralelismos e gateways de decisão do fluxo ETL.

A abordagem foi concebida para acomodar três fontes de dados com características heterogêneas: o IPMA (REST JSON), o SNIRH (web scraping de CSV/XML) e o ERA5/Copernicus (API Python cdsapi com download CSV). Cada fonte possui um mecanismo de ingestão distinto — Script Task C# para IPMA e SNIRH, Execute Process Task com Python para ERA5 — mas todas convergem para o mesmo modelo Bronze–Silver–Gold.

O pipeline foi desenhado segundo os seguintes princípios metodológicos. Primeiro, idempotência: todas as transformações Bronze→Silver e Silver→Gold utilizam MERGE ou INSERT com NOT EXISTS, garantindo que re-execuções não duplicam dados. Segundo, rastreabilidade: cada registo Bronze inclui colunas de auditoria (_arquivo, _run_id, _dt_carga) e cada transformação regista contagens de leitura, escrita e rejeição na tabela logs.ETL_Log. Terceiro, resiliência: registos inválidos são encaminhados para a quarentena (quarentena.ETL_Quarentena) com o motivo de rejeição, sem interromper o pipeline. Quarto, separação de responsabilidades: a validação de tipos e regras de qualidade acontece exclusivamente na camada Silver, enquanto a camada Gold se limita a construir o esquema estrela via MERGE e INSERT.

As ferramentas utilizadas são: SQL Server 2025 como motor de base de dados, SSIS (Integration Services) como orquestrador ETL, C# para Script Tasks de ingestão IPMA e SNIRH, Python 3.13 com cdsapi para ingestão ERA5, e SQL/T-SQL para todas as transformações Bronze→Silver e Silver→Gold. A modelação do pipeline foi documentada em BPMN para representar o fluxo de decisão e paralelismo entre os diversos componentes.

Foram criados os seguintes diagramas BPMN para suportar o nosso desenvolvimento:




Figura 14: BPMN geral




Figura 15: BPMN camada bronze

Descrição: A camada Bronze contém três tarefas de ingestão sequenciais, cada uma especializada numa fonte de dados distinta. O Script Task ST_BronzeIPMA acede à API REST do IPMA e descarrega estações e observações meteorológicas em JSON. O Script Task ST_BronzeSNIRH faz web scraping do portal SNIRH, obtendo séries históricas hidrológicas em CSV. A Execute Process Task EPT_BronzeERA5 invoca um script Python que contacta a CDS API do Copernicus para descarregar dados de reanálise climática. Em todos os casos, os dados são armazenados no formato original, sem qualquer validação ou conversão de tipos. A execução é sequencial porque o ERA5 depende das coordenadas das estações já inseridas pelo IPMA e SNIRH.




Figura 16: BPMN camada silver

Descrição: A camada Silver contém três tarefas de transformação que executam em paralelo, uma por fonte de dados. Cada tarefa segue o mesmo padrão: limpeza e conversão de tipos, normalização e deduplicação dos dados, validação de qualidade com encaminhamento de registos rejeitados para quarentena, e registo de métricas de execução no log ETL.




Figura 17: BPMN camada gold

Descrição: A camada Gold constrói o esquema estrela em duas fases. Na primeira, são carregadas as quatro dimensões — tempo, estação, bacia e parâmetro — podendo executar em paralelo. Na segunda, após todas as dimensões estarem completas, os factos são carregados por fonte, resolvendo as foreign keys via JOINS com as dimensões já povoadas. Todos os INSERTs utilizam NOT EXISTS para garantir idempotência.




Figura 18: BPMN datamart ML

5.2. Mapeamento de Dados

O mapeamento source-to-target do PreFlood_DW cobre 5 tabelas Bronze, 6 tabelas Silver, 4 dimensões Gold e 1 tabela de factos Gold. Para cada camada, detalham-se as transformações aplicadas.

5.2.1. Bronze: Ingestão Bruta

As tabelas Bronze recebem dados exactamente como chegam das fontes externas, sem qualquer validação ou conversão de tipos. Todas as colunas são NVARCHAR para acomodar qualquer formato sem risco de erros. Cada tabela inclui 3 colunas de auditoria: `_arquivo` (ficheiro de origem), `_run_id` (identificador da execução ETL, do tipo UNIQUEIDENTIFIER) e `_dt_carga` (timestamp de carga).

brz.ipma_est: Cadastro de estações meteorológicas do IPMA, proveniente do endpoint `stations.json`. Colunas: `id_estacao`, `nome`, `latitude`, `longitude` (todas NVARCHAR).

brz.ipma_obs: Observações horárias do IPMA, provenientes do endpoint `observations.json`. Colunas: `data_hora`, `id_estacao`, `temperatura`, `humidade`, `pressao`, `vento_km`, `vento_ms`, `vento_dir`, `precipitacao`, `radiacao` (todas NVARCHAR). O JSON original tem estrutura aninhada `{timestamp → {estação → {campos}}}`, que o Script Task C# achata para linhas tabulares.

brz.snirh_est: Cadastro de estações hidrométricas do SNIRH, proveniente do endpoint `xml_listaestacoes.php`. Colunas: `id_estacao`, `nome`, `latitude`, `longitude`, `activa` (todas NVARCHAR).

brz.snirh_obs: Observações hidrológicas do SNIRH, provenientes do endpoint `dados_csv.php`. Colunas: `data_hora`, `id_estacao`, `id_parametro`, `valor` (todas NVARCHAR). O parâmetro já vem desnormalizado (uma coluna por tipo de medição no CSV é convertida para linhas com `id_parametro` pelo Script Task C#). São recolhidos 5 parâmetros: 1843 (Nível Instantâneo), 1845 (Nível Médio Diário), 1850 (Caudal Médio Diário), 3212219030 (Caudal Horário), 354895424 (Cota Última Hora).

brz.era5_obs: Dados de reanálise climática do ERA5/Copernicus, provenientes da CDS API em formato CSV. Colunas: `data_hora`, `latitude`, `longitude`, `temperatura_2m`, `precipitacao`, `solo_l1`, `solo_l2`, `solo_l3`, `solo_l4`, `pressao_superf` (todas NVARCHAR). A região geográfica cobre lat [40,04, 40,63] × lon [-8,89, -6,82] (min,max), com coordenadas arredondadas a 0,1° conforme requisito da CDS API.

5.2.2. Bronze → Silver: Transformações

As transformações Bronze→Silver são implementadas como Stored Procedures T-SQL (scripts 09, 10, 11), executadas via Execute SQL Task no SSIS. Todas seguem o mesmo padrão: registam o início em `logs.ETL_Log`, executam MERGE ou INSERT com NOT EXISTS, registam contagens de lidos/escritos/rejeitados, e encaminham rejeitados para a quarentena.

IPMA Estações (brz.ipma_est → silver.ipma_stations): MERGE por `station_id`. Conversão de coordenadas com `REPLACE(,',' ,'.')` e `ROUND(... , 3)`. Filtragem de `id_estacao` e nome nulos ou vazios. Atribuição de `bacia_codigo = 47`. Na cláusula MATCHED, utiliza `ISNULL(src, tgt)` para preservar valores existentes caso o fonte seja nulo.

IPMA Observações (brz.ipma_obs → silver.ipma_observations): INSERT com NOT EXISTS. A transformação central é o unpivot das 8 colunas métricas (`temperatura`, `humidade`, `pressao`, `vento_km`, `vento_ms`, `vento_dir`, `precipitacao`, `radiacao`) em pares (`parametro_id`, `valor`) via `CROSS APPLY (VALUES ...)`, expandindo 1 linha Bronze em até 8 linhas Silver. Cada coluna é convertida com `TRY_CAST(... AS FLOAT)`. Valores sentinela -99 do IPMA são excluídos. Registos com `data_hora` inválida, estação vazia, ou todos os valores métricos sentinela são encaminhados para quarentena com o motivo específico.

SNIRH Estações (brz.snirh_est → silver.snirh_stations): MERGE por `station_id`. Conversão de coordenadas com `TRY_CAST` (sem `REPLACE(,',' ,'.')`, pois o SNIRH já utiliza ponto decimal). Atribuição de `bacia_codigo = 47`.

SNIRH Observações (brz.snirh_obs → silver.snirh_observations): INSERT com NOT EXISTS. Mapeamento 1:1 — cada linha Bronze produz 1 linha Silver. Conversão de `data_hora` para `DATETIME2`, `id_parametro` para `BIGINT`, `valor` para `FLOAT`. Validação adicional com `ISNUMERIC(valor) = 1`. Registos

com `data_hora` inválida, estação vazia, parâmetro não numérico ou valor não numérico são rejeitados com motivo.

ERA5 Localizações (`brz.era5_obs` → `silver.era5_locations`): MERGE por (`latitude`, `longitude`) com SELECT DISTINCT para deduplicar coordenadas. Validação de latitude em [-90, 90] e longitude em [-180, 180]. Geração automática do `location_label` como CONCAT('ERA5_', `lat`, '_', `lon`). Atribuição de `bacia_codigo` = 47. Não existem updates — apenas inserts de novas coordenadas.

ERA5 Observações (`brz.era5_obs` → `silver.era5_observations`): INSERT com NOT EXISTS, com INNER JOIN a `silver.era5_locations` para resolver o `location_id` via coordenadas arredondadas. A precipitação negativa é corrigida para 0 (CASE WHEN `valor` < 0 THEN 0.0). Validação de temperatura em [180, 350] Kelvin e saturação do solo em [0, 1]. Registos com coordenadas inválidas, temperatura fora do range ou valores do solo fora do intervalo são rejeitados com motivo específico.

5.2.3. Silver → Gold — Esquema Estrela

As transformações Silver→Gold constroem o esquema estrela dimensional e são implementadas como Stored Procedures nos scripts 12, 13 e 14.

Dimensão Tempo (`silver.*_observations` → `gold.dim_tempo`): A SP `ctl.usp_popular_dim_tempo` determina o MIN e MAX de `observation_datetime` nas 3 tabelas de observações Silver, e gera uma linha por hora nesse intervalo. Cada linha contém 14 atributos derivados: `data`, `hora`, `ano`, `mês`, `dia`, `trimestre`, `semana_ano`, `dia_ano`, `dia_semana`, `dia_semana_nome`, `fim_de_semana` e `estação_do_ano` (calculada por CASE: meses 3–5 = Primavera, 6–8 = Verão, 9–11 = Outono, 12–2 = Inverno). A surrogate key `tempo_sk` é IDENTITY(1,1).

Dimensão Estação (`silver.*_stations` + `silver.era5_locations` → `gold.dim_estacao`): Três MERGES independentes, um por fonte. IPMA e SNIRH fazem MERGE por (`estacao_id`, `sistema_origem`), utilizando ISNULL(`src`, `tgt`) nos updates. ERA5 faz MERGE convertendo `location_id` para VARCHAR como `estacao_id`. A chave única é composta (`estacao_id`, `sistema_origem`), permitindo que estações com o mesmo ID de fontes diferentes coexistam com surrogate keys distintas.

Dimensão Bacia (`seed` → `gold.dim_bacia`): Carregada estaticamente com 1 registo: `bacia_codigo` = 47, `bacia_nome` = 'Bacia do Mondego'.

Dimensão Parâmetro (`seed` → `gold.dim_parametro`): Carregada estaticamente com 30 parâmetros: 8 IPMA, 5 SNIRH e 17 ERA5, cada um com `parametro_id`, `parametro_nome`, `parametro_codigo`, `categoria`, `unidade_medida`, `sistema_origem` e `granularidade`.

Tabela de Factos (`silver.*_observations` → `gold.fact_medicao`): Três INSERTs com NOT EXISTS, um por fonte, resolvendo as foreign keys via JOINS com `dim_estacao`, `dim_tempo` e `dim_parametro`. O IPMA faz JOIN por (`station_id`, `parametro_id`, `sistema_origem`). O SNIRH faz JOIN por (`station_id`, `parametro_codigo`, `sistema_origem`) — notar que utiliza `parametro_codigo` e não `parametro_id` porque os códigos SNIRH (1843, 1850, etc.) estão armazenados na coluna `parametro_codigo` de `dim_parametro`. O ERA5 executa 7 INSERTs separados, um por variável (temperatura, precipitação, pressão, saturação do solo L1–L4), cada um com `parametro_id` hardcoded. O grão da tabela de factos é: uma medição de um parâmetro, numa estação, numa hora.

5.3. Modelação do Sistema de Povoamento

O sistema de povoamento foi modelado em BPMN, os respetivos diagramas podem ser encontrados no ponto 5.1 reflectindo a arquitectura do pacote SSIS Pkg_Master.dtsx. O modelo organiza-se em 4 pools sequenciais (Bronze, Silver, Gold, ML), cada uma contendo tarefas que executam em sequência ou em paralelo conforme as dependências de dados.

Tarefa	Tipo SSIS	Fonte	Destino
ST_BronzeIPMA	Script Task (C#)	api.ipma.pt JSON	brz.ipma_est + brz.ipma_obs
ST_BronzeSNIRH	Script Task (C#)	snirh.apambiente.pt CSV/XML	brz.snirh_est + brz.snirh_obs
EPT_BronzeERA5	Execute Process Task	cds.climate.copernicus.eu CSV	brz.era5_obs

Tabela 31: Pool Bronze: Ingestão de dados das 3 fontes

As 3 tarefas Bronze foram executadas sequencialmente no SSIS, embora não existam dependências de dados entre o IPMA e o SNIRH. A razão é que ambas as tarefas partilham variáveis SSIS comuns em versões anteriores do projeto, o que criaria race conditions se executassem em paralelo dentro do mesmo Sequence Container. Adicionalmente, o EPT_BronzeERA5 depende dos dados já inseridos nas tabelas Bronze do IPMA e SNIRH — o script consulta brz.ipma_est e brz.snirh_est para determinar as coordenadas geográficas das estações existentes e calcular os limites de latitude/longitude do pedido ERA5. Assim, a execução sequencial (IPMA → SNIRH → ERA5) garante tanto a ausência de conflitos em variáveis partilhadas como a disponibilidade dos dados de coordenadas para o ERA5.

Tarefa	Tipo SSIS	Fonte	Destino
SQL Transform IPMA	Execute SQL Task	brz.ipma_est/obs	silver.ipma_stations/ observations
SQL Transform SNIRH	Execute SQL Task	brz.snirh_est/obs	silver.snirh_stations/ observations
SQL Transform ERA5	Execute SQL Task	brz.era5_obs	silver.era5_locations/ observations

Tabela 32: Pool Silver — Validação, tipagem e transformação

As 3 transformações Silver podem executar em paralelo, pois operam sobre tabelas Bronze independentes. Cada transformação segue o padrão: logging início → MERGE estações (upsert) → INSERT observações → encaminhar rejeitados para quarentena → logging fim com contagens.

Tarefa	Tipo SSIS	Fonte	Destino
Popular dim_tempo	Execute SQL Task	silver.*_observations	gold.dim_tempo
MERGE dim_estacao	Execute SQL Task	silver.*_stations	gold.dim_estacao
MERGE dim_bacia	Execute SQL Task	Seed	gold.dim_bacia
MERGE dim_parametro	Execute SQL Task	Seed	gold.dim_parametro
INSERT fact_medicao	Execute SQL Task	silver.*_observations	gold.fact_medicao

Tabela 33: Pool Gold — Construção do esquema estrela e preparação ML

O pool Gold executa em sequência: primeiro as dimensões (tempo, estação, bacia, parâmetro), depois os factos (que dependem das foreign keys das dimensões).

Ordem	Tarefa	Destino
1	EPT_SpatialProximity	ctl.map_spatial_proximity
2	EPT_FloodLabeling	ml.flood_labels + ctl.flood_thresholds
3	EPT_FloodML	ml.results
4	EPT_ForecastML	25 modelos .lgb
5	EPT_LSTMflood	3 modelos .keras
6	EPT_PredictNow	ml.predictions_now
7	EPT_ComputeFloodEvents	ml.ew_flood_events
8	EPT_EarlyWarning	ml.ew_detections
9	EPT_UpdateActuals	ml.forecast_predictions

Tabela 34: Pool ML — Pipeline de aquisição de conhecimento (9 tarefas sequenciais)

O pool ML inicia após o Gold estar completo. Todas as 9 tarefas executam sequencialmente no SSIS, ligadas por Precedence Constraints. A primeira tarefa é a construção do mapeamento de proximidade espacial (`build_spatial_proximity.py`), que calcula a distância geodésica (fórmula de Haversine) entre cada estação IPMA/SNIRH e todas as células ERA5, gerando 708 mapeamentos em `ctl.map_spatial_proximity`. Esta tarefa é pré-requisito para todos os modelos ML, que necessitam de alinhar as observações ground-truth com os dados ERA5. De seguida, a rotulagem de cheias (`flood_labeling.py`) gera os labels binários em `ml.flood_labels` e os limiares por estação em `ctl.flood_thresholds`. O clustering não supervisionado (`flood_ml.py`) executa de seguida, operando directamente sobre `gold.fact_medicao` para gerar scores de risco em `ml.results`. Após o clustering, o LightGBM (`forecast_ml.py`) treina 25 modelos de regressão para previsão de nível hidrométrico, e de seguida o LSTM (`lstm_flood.py`) treina 3 modelos de classificação binária de cheia, utilizando os labels gerados na etapa 2 e o mapeamento de proximidade da etapa 1. As três tarefas operacionais seguintes executam sequencialmente: `predict_now.py` carrega os modelos .lgb treinados e gera previsões em tempo real, `compute_flood_events.py` cataloga os eventos históricos de cheia, e `early_warning.py` avalia o risco actual através de 3 camadas e acciona alertas via `ctl.usp_evaluate_alerts`. A tarefa final, `update_actuals.py`, compara as previsões anteriores com os valores observados entretanto disponíveis.

5.4. Implementação do Sistema de Povoamento

A implementação do sistema de povoamento materializa-se em 3 componentes: o pacote SSIS `Pkg_Master.dtsx`, 3 Script Tasks em C# e 20 scripts SQL de transformação.

5.4.1. Ingestão IPMA (ST_BronzeIPMA.cs)

O Script Task em C# acede ao endpoint REST do IPMA (`api.ipma.pt/open-data/observation/meteorology/stations/`) e descarrega dois ficheiros JSON: o cadastro de estações e as observações meteorológicas. A implementação utiliza `HttpClient` para o download, `Newtonsoft.Json` para parsing, e `SqlConnection` para inserção em bulk nas tabelas `brz.ipma_est` e `brz.ipma_obs`. O JSON de observações tem estrutura aninhada (`timestamp` → `estação` → `campos métricos`) que é achata para linhas tabulares. O registo de execução é feito via `sp_ETL_LogInicio` e `sp_ETL_LogFim`. Em caso de falha numa estação individual, o erro é registado mas o processamento continua. A string de ligação e o directório de aterragem estão hardcoded no script.

5.4.2. Ingestão SNIRH (ST_BronzeSNIRH.cs)

O Script Task em C# implementa web scraping do portal SNIRH via HttpClient com criação de sessão por cookies. O fluxo é: (1) POST para iniciar sessão, (2) GET para obter a lista de estações em XML (filtradas por `bacia_codigo=47`), (3) GET sequencial para cada estação e cada um dos 5 parâmetros hidrológicos, descarregando CSV com dados. O parsing do CSV inclui detecção automática de cabeçalho. Os dados são inseridos em `brz.snirh_est` e `brz.snirh_obs`. A string de ligação e o directório de destino estão no script hardcoded.

5.4.3. Ingestão ERA5 (EPT_BronzeERA5 + bronze_era5.py)

O ERA5 é ingerido através de uma Execute Process Task (EPT_BronzeERA5) no pacote SSIS, que invoca `cmd.exe /c python ST_BronzeERA5.py`. Este script Python autonomo contacta a CDS API via `cdsapi.Client().retrieve()`, especificando a região geográfica (lat 39,90, 40,45, lon -8,55, -7,85), as 7 variáveis (temperatura 2m, precipitação total, pressão superficial, saturação do solo L1–L4) e o período temporal. As coordenadas dos pontos de grelha são obtidas da Bronze (`brz.ipma_est`, `brz.snirh_est`) e arredondadas a 0,1° conforme requisito da CDS API. Os CSVs resultantes são parseados e inseridos em `brz.era5_obs`. O script `bronze_era5.py` constitui uma alternativa standalone equivalente para execução fora do SSIS (string de ligação na linha 35, directório na linha 37). As credenciais CDS residem em `/cdsapirc`.

5.4.4. Transformações SQL (Scripts 09–14)

As transformações Bronze→Silver (scripts 09–11) são implementadas como scripts SQL, enquanto as transformações Silver→Gold (scripts 12–14) definem Stored Procedures no esquema `ctl`. Cada bloco Bronze→Silver segue o padrão: (1) declarar variáveis de contagem (Lidos, Escritos, Rejeitados), (2) chamar `sp_ETL_LogInicio` com um UNIQUEIDENTIFIER gerado por `NEWID()`, (3) executar MERGE para estações e INSERT...WHERE NOT EXISTS para observações, (4) encaminhar rejeitados para `quarentena.ETL_Quarentena`, (5) chamar `sp_ETL_LogFim`. Este padrão é consistente nos 3 scripts Bronze→Silver, garantindo rastreabilidade e isolamento de dados inválidos.

As transformações Silver→Gold são executadas por SPs: `ctl.usp_popular_dim_tempo` (dimensão temporal), `ctl.usp_merge_dim_estacao_ipma/snirh` e `ctl.usp_criar_estacoes_era5` (dimensão estações), e 3 SPs para a tabela de factos (`ctl.usp_merge_ipma`, `ctl.usp_merge_snirh`, `ctl.usp_merge_era5`).

5.4.5. Logging e Quarentena

É composto por 2 tabelas e 3 SPs. A tabela `logs.ETL_Log` regista cada passo com `Execucao_Id` (GUID), `Fase`, `Passo`, `Status` (INICIO/OK/ERRO), contagens de registos, duração em segundos e detalhes de erro. A tabela `logs.Ficheiros_Processados` rastreia cada ficheiro processado. Os 3 SPs (`sp_ETL_LogInicio`, `sp_ETL_LogFim`, `sp_ETL_RegistarErro`).

A quarentena (`quarentena.ETL_Quarentena`) captura registos rejeitados com o campo `Dados_Registo` serializado como JSON (via `FOR JSON PATH, WITHOUT_ARRAY_WRAPPER`), permitindo inspecção e reprocesamento posterior. O campo `Resolvido` suporta um workflow manual de resolução.

5.5. Validação e Testes

O processo de validação do sistema de povoamento foi aplicado em 4 níveis: validação de dados, validação de transformações, validação de integridade referencial e validação de performance.

5.5.1. Validação de Dados

Após o povoamento completo, foram verificadas as contagens de registos em cada camada contra os valores esperados. A camada Bronze contém 2 521 857 registos totais (IPMA: 18 219 observações + 888 estações; SNIRH: 683 844 observações + 14 estações; ERA5: 1 120 896 observações). A camada Silver

contém os mesmos dados validados e tipados. A camada Gold contém 8 354 562 factos, 244 estações e 31 parâmetros.

Foram igualmente verificadas as contagens de registos rejeitados na quarentena, validando que os motivos de rejeição são coerentes com as regras implementadas (datas inválidas, valores sentinela -99, valores não numéricos).

5.5.2. Validação de Transformações

Cada transformação Bronze→Silver foi testada individualmente executando o script SQL correspondente e verificando: (1) que o MERGE actualiza registos existentes sem duplicar, (2) que o INSERT com NOT EXISTS é idempotente, (3) que o TRY_CAST filtra correctamente valores inválidos.

As transformações Silver→Gold foram validadas executando as SPs de carga de dimensões e factos e verificando: (1) que todas as foreign keys resolvem correctamente via JOINS, (2) que a dimensão tempo cobre o intervalo completo de datas, (3) que a dimensão estação integra as 3 fontes sem duplicações, (4) que o INSERT de factos não viola a constraint única (estacao_sk, tempo_sk, parametro_sk).

5.5.3. Validação de Integridade Referencial

Foram executadas queries de verificação de integridade referencial para confirmar que: (1) todos os estacao_sk em fact_medicao existem em dim_estacao, (2) todos os tempo_sk existem em dim_tempo, (3) todos os parametro_sk existem em dim_parametro, (4) todos os bacia_codigo em dim_estacao existem em dim_bacia. Não foram encontradas violações de integridade referencial.

5.5.4. Validação de Performance

O tempo de execução do pipeline completo Bronze→Gold foi medido em 8 minutos para a carga inicial, registado na tabela logs.ETL_Log. A fase de extracção domina o tempo total, sendo o ERA5 o mais custoso com 4m08s devido à natureza da CDS API que coloca o pedido numa fila de espera antes do download, seguido do SNIRH com 3m11s pelo download de 16 anos de dados via web scraping. As transformações Silver consomem 38s no total, com a transformação ERA5 a consumir 24s devido à validação de 1,1 milhões de observações e rejeição de 18.022 registos com precipitação negativa. A fase de carregamento Gold (dimensões + factos) executa em menos de 1 segundo. Em cargas incrementais diárias (IPMA + SNIRH + ERA5), o tempo estimado é inferior a 5 minutos, sendo o IPMA extraído em 2s.

5.5.5. Validação do Pipeline ML

O pipeline ML completo foi executado e validado em sequência, confirmando que: (1) build_spatial_proximity.py gera 708 mapeamentos de proximidade, (2) flood_labeling.py produz 375 834 labels com cobertura dos 4 eventos históricos de backtest, (3) flood_ml.py gera 49 904 resultados de clustering e anomalias, (4) forecast_ml.py treina 25 modelos LightGBM, (5) lstm_flood.py treina 3 modelos LSTM, (6) predict_now.py gera 15 predições em tempo real, (7) compute_flood_events.py cataloga 584 eventos históricos, (8) early_warning.py detecta 3 alertas, (9) update_actuals.py marca 30 predições como pendentes.

6. Exploração e Análise de Dados

6.1. Organização geral do sistema de dashboarding

A exploração e visualização de dados do PreFlood_DW foi projectada para servir quatro perfis de agente de decisão previamente caracterizados: o Analista Hidrológico (AH), o Responsável de Protecção Civil (RPC), o Decisor Estratégico (DE) e o Administrador do Sistema (AS). Cada perfil possui necessidades de análise distintas — desde a monitorização em tempo real do nível dos rios até à auditoria da qualidade dos dados, o que torna impraticável uma abordagem de *dashboard único*.

Adoptou-se uma arquitectura baseada em quatro dashboards sobre o esquema Gold e os esquemas auxiliares (ml, ctl). A separação dos dashboards não é meramente estética: reflecte diferenças na frequência de consulta (tempo real vs. diário vs. mensal), no nível de detalhe técnico exigido e na sensibilidade das informações (por exemplo, os alertas activos são exclusivos do RPC, enquanto as métricas de qualidade dos dados são exclusivas do AS).

Dashboard	Perfil	Foco
Executivo	DE	Tendências, eventos anuais, risco comparado
Técnico-Hidrológico	AH	Séries temporais, percentis, saturação do solo
Meteorológico-Operacional	RPC	Alertas, detecção precoce, probabilidades
Monitorização do Sistema	AS	ETL, quarentena, modelos, qualidade

Tabela 35: Dashboards por perfil de decisão

6.2. Serviços de exploração e análise implementados

6.2.1. Dashboard Técnico-Hidrológico (Perfil AH)

O dashboard do Analista Hidrológico é o mais extenso, servindo 10 requisitos (AH01–AH09). A vista `vw_medicoes_detalhe` fornece o dataset completo desnormalizado — cada linha contém a estação, o timestamp, o parâmetro e o valor, com JOINS às dimensões — permitindo ao analista explorar livremente as séries temporais. As vistas `vw_medicoes_por_estacao` e `vw_medicoes_por_mes` fornecem agregações estatísticas (contagem, média, desvio padrão, mínimo, máximo) por estação e por mês, respectivamente, cobrindo os requisitos AH01 (exploração por estação/período) e AH08 (cobertura por estação).

Para o requisito AH03 (análise por percentis), a vista `vw_ah_percentis_historicos` expõe os limiares P50, P75, P90, P95 e P99 por estação, calculados sobre os dados históricos do nível instantâneo. O requisito AH04 (eventos de cheia) é servido pela vista `vw_ah_eventos_cheia`, que apresenta os 584 eventos catalogados com data de início, pico, fim, duração e nível máximo atingido. O requisito AH05 (análise espacial) é coberto pela vista `vw_ah_proximidade_espacial`, que expõe as 708 ligações de proximidade entre estações IPMA/SNIRH e os pontos de grelha ERA5, permitindo ao analista compreender como os dados meteorológicos se relacionam espacialmente com as estações de medição.

O requisito AH06 (correlação solo-precipitação-nível) é servido pela vista `vw_ah_saturacao_solo`, que agrega os dados ERA5 de saturação do solo (camada L1) por ponto de grelha, em conjunto com a vista `vw_pbi_era5_daily` que apresenta as agregações diárias de precipitação, temperatura e pressão. O requisito AH09 (níveis de albufeira) é coberto pela vista `vw_ah_niveis_albufeira`, que mostra os níveis actuais e as previsões para as barragens, e pela vista `vw_risco_atual` que inclui as cotas de albufeira.

6.2.2. Dashboard Meteorológico-Operacional (Perfil RPC)

O dashboard do Responsável de Protecção Civil serve 5 requisitos (RPC01–RPC05) com foco na operacionalidade em tempo real. O requisito RPC01 (detecção de anomalias) é coberto pela vista `vw_anomalias`, que apresenta as observações marcadas como anómalas pelo IsolationForest. O requisito RPC02 (alertas activos) é servido pela vista `vw_rpc_alertas_ativos`, que lista os alertas gerados pelo sistema com detalhe do nível de risco, estação afectada e timestamp, e pela vista `vw_rpc_deteccao_precoce` que implementa o sistema de detecção em 3 camadas (observação, previsão, probabilidade).

O requisito RPC03 (probabilidade de cheia LSTM) é coberto pela vista `vw_pbi_lstm`, que expõe as previsões do classificador LSTM por horizonte (6h, 12h, 24h) com a probabilidade de cheia associada. O requisito RPC04 (painel de risco integrado) é servido pelas vistas `vw_risco_atual` e `vw_risco_unpivot`, que apresentam o risco combinado por estação e as previsões desnormalizadas por horizonte. O requisito RPC05 (qualidade das previsões) é coberto pela vista `vw_previsoes_detalhe` (previsões LightGBM com erros) e `vw_metricas_modelo` (métricas de qualidade dos modelos).

6.2.3. Dashboard Executivo (Perfil DE)

O dashboard do Decisor Estratégico serve 4 requisitos (DE01–DE04) com foco em visão agregada e tendências. O requisito DE01 (visão geral anual) é coberto pela vista `vw_de_eventos_anual`, que agrega os eventos de cheia por ano (contagem, duração média, nível máximo), e pela vista `vw_pbi_ml_results` que apresenta os resultados de clustering e anomalias. O requisito DE02 (comparação de risco) é servido pelas vistas `vw_risco_atual` e `vw_risco_unpivot`, permitindo comparar o nível de risco entre estações e horizontes de previsão. O requisito DE03 (catálogo de eventos) é coberto directamente pela tabela `ml.ew_flood_events`. O requisito DE04 (tendências climáticas) é servido pela vista `vw_de_tendencia_climatica` (tendências anuais ERA5) e pela vista `vw_medicoes_por_mes` (agregação mensal).

6.2.4. Dashboard de Monitorização do Sistema (Perfil AS)

O dashboard do Administrador serve 7 requisitos (AS01–AS07) com foco na saúde operacional do sistema. Os requisitos AS01 e AS02 (monitorização ETL) são cobertos pelas vistas `vw_etl_resumo_diario` (execuções do dia), `vw_etl_resumo_historico` (histórico completo) e `vw_etl_timeline` (timeline com indicação visual de estado). O requisito AS03 (registo de modelos) é servido pela vista `vw_as_modelos_registo` (modelos treinados), `vw_as_limiares` (limiares consolidados) e `vw_metricas_modelo` (métricas de qualidade). O requisito AS04 (qualidade dos dados) é coberto pela vista `vw_quarentena_resumo` (registos rejeitados) e pela vista `vw_as_qualidade_dados` (qualidade detalhada por fonte). Os requisitos AS05 e AS06 (segurança e auditoria) são garantidos nativamente pelo Power BI e pelo SQL Server Audit. O requisito AS07 (estado das fontes) é servido pela vista `vw_as_fontes_estado`, que apresenta a latência e o estado de cada fonte de dados.

7. Previsão de Cheias

7.1. Definição do problema e compreensão dos elementos de análise envolvidos

O problema central que o PreFlood_DW se propõe a resolver é a *previsão de cheias fluviais na bacia hidrográfica do rio Mondego*, com antecedência suficiente para permitir a tomada de decisão por parte dos agentes de protecção civil e gestão de recursos hídricos. O Mondego é o maior rio exclusivamente português, com uma bacia de aproximadamente 6640 km², historicamente sujeita a episódios de cheia com impacte significativo em populações e infraestruturas.

O problema é formulado de duas formas complementares:

1. *Previsão de nível de água* (regressão) — prever o nível instantâneo do rio em cada estação de medição natural para horizontes de 1h, 3h, 6h, 12h e 24h, utilizando como *inputs* séries temporais de nível, precipitação, temperatura, pressão atmosférica e saturação do solo.
2. *Classificação de cheia* (classificação binária) — classificar cada instante temporal como “cheia” ou “normal” para horizontes de 6h, 12h e 24h, com base num limiar de percentil P95 do nível histórico por estação.

Os elementos de análise envolvidos incluem dados de três fontes heterogéneas: medições hidrométricas e meteorológicas in situ do SNIRH (16 anos, 10 estações na bacia), observações meteorológicas do IPMA (14 estações próximas) e dados de reanálise ERA5 do Copernicus (14 pontos de grelha, 7 variáveis). A integração destas fontes no esquema Gold da base de dados resulta numa tabela de factos `gold.fact_medicao` com 8,35 milhões de registos, abrangendo 244 estações e 31 parâmetros.

Um aspecto fundamental do problema é a distinção entre estações naturais e estações de barragem. As estações de barragem têm o nível controlado por gestão humana (comportas, turbinagem), pelo que o seu nível não reflecte processos hidrológicos naturais. Consequentemente, apenas as estações naturais são utilizadas como alvos de previsão.

A abordagem de resolução assenta numa arquitectura de modelos híbridos, combinando:

1. **LightGBM híbrido** (global + local) para previsão de nível — um modelo global treinado sobre todas as estações captura os padrões gerais, complementado por modelos locais por estação que aprendem os resíduos específicos de cada localização.
2. **LSTM binário** para classificação de cheia — uma rede neuronal recorrente que opera sobre janelas de 48 horas (*lookback*) de 20 *features*, classificando a probabilidade de cheia para cada horizonte.
3. **Scoring de risco ponderado** — uma fórmula combinada que integra 5 componentes (40% nível relativo, 20% taxa de subida, 15% máximo rolling, 15% precipitação acumulada, 10% saturação do solo) num índice de risco normalizado entre 0 e 1.

7.2. Selecção e preparação dos dados

A preparação de dados para o modelo de previsão segue um pipeline em 3 fases, implementado por 9 scripts Python sequenciais:

Script	Acção	Resultado
build_spatial_proximity.py	Mapeamento estações→ERA5	708 ligações
flood_labeling.py	Labels binários P95	375.834 labels
flood_ml.py	Clustering + risco	49.904 resultados
forecast_ml.py	Treino LightGBM híbrido	25 modelos .lgb
lstm_flood.py	Treino LSTM	3 modelos .keras
predict_now.py	Previsão em tempo real	15 preds + 9 LSTM
compute_flood_events.py	Catálogo eventos	584 eventos
early_warning.py	Detecção 3 camadas	Detecções activas
update_actuals.py	Actualização observações	Actualizações pendentes

Tabela 36: Pipeline ML — scripts, acções e resultados

A engenharia de *features* é o passo mais crítico. Para o LightGBM, cada observação inclui: lags do nível até 336h (14 dias), *deltas* de 1h a 24h, médias/máximos/desvios *rolling* de 3h a 72h, acumulados de precipitação ERA5 de 6h a 168h, estatísticas da estação (P50–P99), níveis de estações vizinhas com lag, caudais de barragens com lag, e codificação cíclica de hora e mês. Isto resulta em tipicamente 150–200 *features* por observação, das quais as mais relevantes são seleccionadas pelo modelo através do *feature importance* intrínseco do LightGBM.

Para o LSTM, a preparação gera sequências de 48 horas de comprimento (*lookback*) com 20 *features* seleccionadas: nível actual e 2 lags (1h, 3h, 6h), 3 *deltas*, 4 estatísticas *rolling*, 3 variáveis ERA5 (precipitação, temperatura, pressão) com acumulados, e 4 variáveis cíclicas temporais. Cada sequência é normalizada com RobustScaler ajustado ao treino, e as *labels* são obtidas da tabela `ml.flood_labels` (coluna `flood_6h`, `flood_12h` ou `flood_24h` conforme o horizonte).

O desbalanceamento de classes é tratado por *undersampling* com rácio 1:3 (positivo:negativo) no treino do LSTM, complementado por `class_weight` dinâmico baseado na proporção real das classes.

7.3. Identificação e fundamentação da técnica de análise

A selecção das técnicas de análise foi guiada pela natureza do problema e pelas características dos dados disponíveis:

LightGBM para regressão de nível — O Gradient Boosting usamos para regressão em dados tabulares com *features* heterogéneas (numéricas, categóricas, com missings). O LightGBM foi escolhido sobre o XGBoost pela sua eficiência em conjuntos de dados grandes (8,35M de registos), pelo suporte nativo de valores em falta e pela velocidade de inferência. A arquitectura híbrida (global + local) é motivada pelo facto de que, embora existam padrões hidrológicos comuns a todas as estações (capturados pelo modelo global), cada estação natural tem características específicas de bacia, altitude e geomorfologia que justificam um modelo correctivo local treinado sobre os resíduos do modelo global.

LSTM para classificação de cheia — As redes LSTM (Long Short-Term Memory) são particularmente adequadas para dados de séries temporais com dependências de longo prazo, como é o caso dos

processos hidrológicos onde a precipitação acumulada ao longo de dias afecta o nível do rio horas depois. A arquitectura LSTM(64)→Dropout(0,2)→LSTM(32)→Dropout(0,2)→Dense(16, ReLU)→Dense(1, Sigmoid) foi escolhida por equilibrar capacidade de representação com robustez contra *overfitting*, sendo treinada com *EarlyStopping* baseado no AUC. A classificação binária é preferida à regressão directa do nível de cheia porque: (a) o limiar de cheia é estação-específico (P95), tornando a regressão seguida de limiarização equivalente mas mais complexa; (b) a função de perda binary cross-entropy optimiza directamente a separação entre classes; (c) a saída probabilística (0–1) é directamente interpretável como probabilidade de cheia.

Scoring de risco ponderado — A fórmula de risco combinado integra múltiplos indicadores numa única métrica, com pesos definidos com base na literatura hidrológica: o nível relativo ao P99 (40%) é o indicador primário, a taxa de subida (20%) captura a velocidade de elevação, o máximo *rolling* 24h (15%) indica pressão sustentada, a precipitação acumulada (15%) reflecte o input atmosférico, e a saturação do solo (10%) indica a capacidade de infiltração.

7.4. Construção do modelo de previsão

7.4.1. Modelo LightGBM híbrido (previsão de nível)

O modelo de previsão de nível é treinado pelo script `forecast_ml.py`, que implementa a arquitectura híbrida global+local:

O **modelo global** é treinado com dados de todas as estações naturais combinadas, utilizando `TimeSeriesSplit` com 5 *folds* para validação cruzada temporal. Os hiperparâmetros são: `num_leaves = 127`, `learning_rate = 0,05`, `n_estimators = 1000` com *early stopping* em 50 rounds, e `objective = regression`. A métrica de optimização é o MAE, com o P90 recebendo peso 3× durante o treino para priorizar a precisão nos valores extremos — estes são os mais relevantes para a previsão de cheias. Para cada horizonte (1h, 3h, 6h, 12h, 24h) é treinado um modelo global independente.

Os **modelos locais** são treinados por estação, aprendendo a corrigir os resíduos do modelo global. Cada modelo local utiliza 20 rounds com `learning_rate = 0,01`, sendo supervisionado pela diferença entre o valor real e a previsão global. Isto resulta em 5 modelos globais + 20 modelos locais (4 estações × 5 horizontes) = 25 modelos .lgb armazenados no directório `Models/models/`.

O modelo utiliza a normalização `RobustScaler` (baseada na mediana e IQR) para resistir a *outliers*, e o *feature importance* é extraído automaticamente pelo LightGBM para interpretabilidade.

7.4.2. Modelo LSTM (classificação de cheia)

O classificador LSTM é treinado pelo script `lstm_flood.py` para 3 horizontes (6h, 12h, 24h). A preparação dos dados gera sequências de 48 horas de 20 *features*, normalizadas por `RobustScaler` ajustado ao treino. O conjunto de dados é dividido temporalmente (70% treino, 15% validação, 15% teste), preservando a ordem cronológica para evitar *data leakage*.

A arquitectura da rede é:

1. LSTM(64, `return_sequences=True`) — primeira camada com 64 unidades, retornando a sequência completa
2. Dropout(0,2) — regularização
3. LSTM(32) — segunda camada com 32 unidades, retornando apenas o último estado
4. Dropout(0,2) — regularização
5. Dense(16, `activation=ReLU`) — camada densa intermédia
6. Dense(1, `activation=Sigmoid`) — saída probabilística

O treino utiliza optimizador Adam com *Cosine Decay* (taxa inicial = 10^{-3} , decaimento ao longo das épocas), *batch size* de 512, e *early stopping* com paciência de 3 épocas monitorando o AUC na validação. O limiar de classificação é optimizado por *grid search* no conjunto de validação para maximizar o F1-score.

7.4.3. Scoring de risco e classificação

O script `flood_ml.py` implementa um pipeline de análise de risco em 3 etapas: (1) clustering K-Means com $k = 5$ para identificar regimes hidrológicos; (2) detecção de anomalias por IsolationForest (*contamination* estimada) e HDBSCAN (*density-based*); (3) cálculo do risco combinado pela fórmula ponderada. O risco é depois classificado em 5 níveis (Muito Baixo, Baixo, Moderado, Alto, Muito Alto) com base nos quantis por estação.

7.5. Validação do desempenho do modelo

A validação dos modelos segue metodologias distintas conforme o tipo:

LightGBM (regressão) — A validação utiliza `TimeSeriesSplit` com 5 *folds*, que respeita a ordem temporal dos dados (cada *fold* de treino contém apenas dados anteriores ao *fold* de teste). Os resultados por horizonte são:

Horizonte	R ²	MAE (m)	RMSE (m)
1h	0,9972	0,012	0,024
3h	0,9924	0,022	0,044
6h	0,9891	0,028	0,053
12h	0,9843	0,036	0,063
24h	0,9754	0,052	0,087

Tabela 37: Métricas do modelo LightGBM híbrido por horizonte de previsão

O R² superior a 0,97 em todos os horizontes indica que o modelo explica mais de 97% da variância do nível observado. A degradação gradual com o horizonte é esperada e consistente com a literatura em hidrologia.

LSTM (classificação) — A validação utiliza divisão temporal (70/15/15) com métricas de classificação:

Horizonte	AUC-ROC
6h	0,84
12h	0,81
24h	0,78

Tabela 38: Métricas do classificador LSTM por horizonte

Os valores de AUC-ROC entre 0,78 e 0,84 são considerados bons para classificação de eventos extremos com forte desbalanceamento (5,9% de cheias no horizonte 6h, 7,5% no horizonte 24h). A métrica CSI (Critical Success Index) é particularmente relevante em hidrologia por penalizar tanto os falsos alarmes como as omissões de eventos críticos.

Backtesting qualitativo — Adicionalmente à validação quantitativa, os modelos foram submetidos a back-testing sobre 4 eventos históricos de cheia conhecidos (Janeiro 2001, Janeiro-Fevereiro 2016, Dezembro 2019, Fevereiro 2026). Estes eventos não foram utilizados no treino do LSTM (excluídos do período de treino), permitindo avaliar a capacidade de generalização do modelo.

7.6. Avaliação dos resultados

Os resultados do pipeline de previsão demonstram a viabilidade de uma abordagem baseada em Data Lakehouse para a previsão de cheias na bacia do Mondego:

O modelo LightGBM atinge um R^2 de 0,997 no horizonte de 1 hora, degradando graciosamente até 0,975 no horizonte de 24 horas. Estes valores indicam que o modelo é adequado para previsão operacional de curto prazo, com erros absolutos médios de 1,2 cm (1h) a 5,2 cm (24h) — dentro da margem de precisão dos sensores hidrométricos. A arquitectura híbrida demonstra que os modelos locais corrigem sistematicamente os resíduos do modelo global, especialmente nas estações com comportamento hidrológico mais singular (como a SK 233 — Ribeira de Nisa).

O classificador LSTM demonstra capacidade de discriminação entre situações de cheia e normais, com AUC de 0,84 no horizonte de 6 horas. O backtesting qualitativo sobre eventos históricos confirma que o modelo activa probabilidades elevadas durante os picos de cheia, embora com algum atraso na detecção do início do evento — comportamento esperado dado que o modelo depende de observações passadas (janela de 48h) para formar a previsão.

O sistema de *early warning* em 3 camadas (observação → previsão → probabilidade) produz 3 detecções activas sobre as 3 estações operacionais (SK 229, 232, 233), com nível de risco “Muito Baixo” e alerta “BAIXO” no momento da avaliação — consistente com as condições hidrológicas observadas (período estival). O catálogo de 584 eventos históricos de cheia calculado pelo `compute_flood_events.py` fornece uma base de referência para a contextualização dos eventos detectados.

Em síntese, os resultados validam a arquitectura proposta: o modelo de regressão LightGBM fornece previsões numéricas precisas do nível da água, o classificador LSTM fornece uma avaliação probabilística do risco de cheia, e o scoring de risco ponderado integra múltiplos indicadores numa métrica de decisão acionável. A combinação destas três abordadas num pipeline automatizado permite que o sistema funcione de forma autónoma, gerando previsões e alertas a cada hora sem intervenção manual.

8. Conclusões e Trabalho Futuro

8.1. Conclusões

O presente trabalho teve como objectivo a conceção, desenvolvimento e implementação de um sistema de suporte à decisão para a previsão e monitorização de cheias na bacia hidrográfica do rio Mondego. O sistema integra múltiplas fontes de dados hidrometeorológicos: SNIRH, IPMA e ERA5 numa arquitetura Data Lakehouse estruturada em sete esquemas relacionais (bronze, silver, gold, ml, ctl, quarentena e logs), suportada por um processo ETL implementado em SSIS e Python.

Do ponto de vista dos **aspetos positivos**, salientam-se os seguintes:

1. **Integração multivariada de fontes heterogéneas:** O sistema consolida dados de três fontes com granularidades, formatos e períodos temporais distintos, totalizando mais de 8,3 milhões de registos na tabela de factos, cobrindo 244 estações e 31 parâmetros hidrometeorológicos ao longo de 16 anos.
2. **Pipeline de Machine Learning funcional:** Foram treinados e validados 25 modelos LightGBM para previsão de níveis hidrométricos em múltiplos horizontes (1h a 24h), com coeficientes de determinação R^2 superiores a 0,97, e 3 modelos LSTM para classificação de probabilidade de cheia, com AUC entre 0,78 e 0,84. O pipeline completo — desde a construção de features espaciais até à geração de previsões e deteção precoce — opera de forma integrada e reproduzível.
3. **Arquitetura de qualidade de dados:** A implementação de uma zona de quarentena dedicada, com registo sistemático de rejeições e motivos de exclusão, confere transparência ao processo de transformação. Foram identificados e isolados 18.022 registos com precipitação negativa do ERA5, posteriormente clampados a zero na camada Silver.
4. **Dashboards web interativos:** Em alternativa à inicialmente prevista integração com Power BI, foram desenvolvidos dashboards web reativos (React + Express) com quatro perfis de acesso diferenciados — Analista Hidrológico, Proteção Civil, Decisor Estratégico e Administrador do Sistema — perfazendo 29 endpoints API e visualizações cartográficas, temporais e analíticas.
5. **Processo ETL robusto e auditável:** O registo exaustivo de cada passo ETL na tabela `logs.ETL_Log`, com métricas de registos lidos, escritos e rejeitados, permite a auditoria completa de qualquer execução.

Relativamente aos **aspetos negativos** e limitações identificadas:

1. **Cobertura temporal assimétrica:** Os dados SNIRH apresentam lacunas significativas em várias estações, particularmente nos registos de precipitação (apenas 4.557 observações). Os dados IPMA, embora abundantes em registos de observação, não incluem medições de nível ou caudal, limitando a sua utilidade directa para os modelos de previsão hidrológica.
2. **Classificação incorrecta de estações IPMA:** Todas as 222 estações IPMA foram importadas com `bacia_codigo = 47`, incluindo estações geograficamente distantes da bacia do Mondego (Açores, Madeira, Alentejo). Sendo isto um erro grave porque os dados não correspondem à realidade.
3. **Modelos treinados com dados limitados de cheias graves:** A maioria dos eventos de cheia registados (584 no total) são classificados como “Leves”, com poucos eventos “Graves”. Esta assimetria pode enviesar os modelos de classificação, particularmente o LSTM, na deteção de cenários extremos.
4. **Ausência de dados de validação em tempo real:** As previsões geradas pelos modelos LightGBM não dispõem de valores reais (`actual_value`) para comparação imediata, uma vez que o processo de

actualização (`update_actuals.py`) requer execução manual posterior. Isto impede a avaliação contínua da precisão das previsões.

5. **Estações de barragem excluídas do risco corrente:** A tabela `ml.flood_risk_current` apenas contém registos para estações naturais (SK 229, 232, 233), não cobrindo as 10 estações de barragem, cujos níveis são controlados artificialmente. Embora esta exclusão seja conceptualmente justificada, limita a visibilidade global do sistema sobre a infraestrutura hidráulica da bacia.
6. **Não implementação das vistas em Power BI:** A integração com Power BI, inicialmente planeada como camada de apresentação, não foi concluída, tendo sido abandonada a meio. Embora tenham sido criadas vistas SQL optimizadas para consumo pelo Power BI. Em substituição, optou-se por dashboards web desenvolvidos em React + Express, que, embora funcionais e interativos, não oferecem a mesma flexibilidade analítica e capacidade de exploração ad-hoc que o Power BI proporcionaria a utilizadores não técnicos.

8.2. Trabalho Futuro

Com base na experiência adquirida e nas limitações identificadas, propõem-se as seguintes melhorias e extensões ao sistema `PreFlood_DW`:

8.2.1. Integração efectiva com Power BI

A prioridade mais imediata é a conclusão da integração com Power BI, aproveitando as 13 vistas SQL e medidas DAX já desenvolvidas. Recomenda-se a instalação de um On-premises Data Gateway para permitir refresh agendado e publicação no Power BI Service. As vistas criadas (`vw_medicoes_detalhe`, `vw_risco_atual`, `vw_previsoes_detalhe`, entre outras) estão optimizadas para consumo directo, minimizando a complexidade dos modelos semânticos. A dupla abordagem — dashboards web para visualização operacional em tempo real e Power BI para análise exploratória e relatórios periódicos — oferece o melhor de ambas as soluções.

8.2.2. Correção da classificação geográfica das estações IPMA

A atribuição automática de `bacia_codigo = 47` a todas as estações IPMA deve ser substituída por uma classificação baseada em coordenadas geográficas, utilizando poligonais oficiais das bacias hidrográficas portuguesas. Esta correção eliminaria a necessidade de filtros artificiais e garantiria a consistência territorial dos dados.

8.2.3. Automatização do pipeline de actualização de valores reais

O script `update_actuals.py` deve ser integrado no processo ETL como um passo automático subsequente à execução dos modelos de previsão. Isto permitiria o preenchimento contínuo dos valores reais nas tabelas de previsões, viabilizando o cálculo automatizado de métricas de erro e a monitorização da degradação dos modelos ao longo do tempo.

8.2.4. Expansão dos modelos de Machine Learning

- **Reequilíbrio de classes para LSTM:** A aplicação de técnicas de oversampling (SMOTE) ou ponderação de classes no treino do LSTM poderia melhorar a deteção de eventos graves, actualmente sub-representados no conjunto de treino.
- **Modelos híbridos físico-data-driven:** A integração de variáveis hidrodinâmicas simuladas (ex: modelo HEC-RAS para a bacia do Mondego) como features adicionais nos modelos LightGBM poderia aumentar a precisão das previsões em cenários de cheia extrema.

- **Auto-retreino periódico:** Implementar um mecanismo de re-treino automático mensal ou trimestral, com avaliação de drift nos dados de entrada, garantiria que os modelos se mantivessem atualizados face a mudanças sazonais e climáticas.

8.2.5. Extensão do sistema de alertas e notificações

O módulo de alertas (`ctl.alerts`) deve ser estendido com notificações proativas por SMS e email, integrando serviços como Twilio ou SMTP. O mecanismo de deteção precoce (`early_warning.py`) deve ser executado em frequência horária, em vez de manual, via SQL Server Agent Job.

8.2.6. Inclusão de estações de barragem no modelo de risco

Embora os níveis das barragens sejam controlados, a monitorização das cotas em tempo real é relevante para a gestão preventiva. Propõe-se a criação de um modelo de risco específico para barragens, com limiares adaptados ao regime de exploração de cada albufeira, alimentado pela vista `vw_albufeiras` já desenvolvida.

8.2.7. Enriquecimento com dados de radar e satélite

A integração de imagens de radar meteorológico (ex: produto composição do IPMA) e índices de vegetação satelitares (NDVI do Sentinel-2) como variáveis auxiliares permitiria capturar padrões espaciais de precipitação e absorção do solo que não são visíveis nos dados pontuais das estações.

8.2.8. Mecanismo de controlo de versões dos modelos

A tabela `ctl.ml_models` deve ser complementada com um sistema de versionamento semântico e rollback automático, permitindo reverter para versões anteriores dos modelos caso as métricas de validação se degradem após um re-treino.

8.2.9. Deploy em ambiente de produção

O sistema deve ser migrado para um ambiente de produção com:

- SSISDB configurado no SQL Server com Agent Jobs para execução automática do ETL
- API Express alojada em serviço Windows (PM2 ou node-windows) com HTTPS
- Dashboard web publicado em IIS ou servidor dedicado
- Monitorização centralizada via Application Insights ou equivalente

8.2.10. Validação com entidades externas

Por fim, recomenda-se a validação dos modelos e alertas com entidades operacionais — nomeadamente a Comissão de Coordenação e Desenvolvimento Regional do Centro e o Sistema Nacional de Protecção Civil, de forma a calibrar os limiares de alerta e as probabilidades de cheia às necessidades operacionais reais de decisão e resposta.

Bibliografia

- Assembleia da República. (2021,). *Lei n.º 68/2021, de 26 de agosto: Aprova os princípios gerais em matéria de dados abertos e transpõe para a ordem jurídica interna a Diretiva (UE) 2019/1024 relativa aos dados abertos e à reutilização de informação do setor público*. <https://diariodarepublica.pt/dr/detalhe/lei/68-2021-170221042>
- European Environment Agency. (2024,). *Economic losses from climate-related extremes*. <https://www.eea.europa.eu/en/analysis/indicators/economic-losses-from-climate-related>
- Parlamento Europeu, & Conselho da União Europeia. (2019,). *Diretiva (UE) 2019/1024 do Parlamento Europeu e do Conselho, de 20 de junho de 2019, relativa aos dados abertos e à reutilização de informações do setor público*. <https://eur-lex.europa.eu/legal-content/PT/TXT/PDF/?uri=CELEX:32019L1024>
- Público. (2026,). *Google anuncia Groundsource com a ambição de "prever o imprevisível" e travar catástrofes*. <https://www.publico.pt/2026/03/13/enter/noticia/google-anuncia-groundsource-ambicao-prever-imprevisivel-travar-catastrofes-2167886>
- World Meteorological Organization. (2023,). *Triple dividends of early warning systems*. [https://wmo.int/media/magazine-article/triple-dividends-of-early-warning-systems-and-climate-services#:~:text=The%20Global%20Commission%20on%20Adaptation%20\(GCA\)%20underscores,losses%20of%20US\\$%203%20billion%E2%80%93US\\$%2016%20billion6](https://wmo.int/media/magazine-article/triple-dividends-of-early-warning-systems-and-climate-services#:~:text=The%20Global%20Commission%20on%20Adaptation%20(GCA)%20underscores,losses%20of%20US$%203%20billion%E2%80%93US$%2016%20billion6)

9. Lista de Siglas e Acrónimos

- DW – Data Warehouse
- ETL – Extract, Transform, Load
- OLAP – On-Line Analytical Processing
- OLTP - Sistemas Operacionais Transacionais
- PT - Personal Trainer
- SCD - Slowly Changing Dimensions
- SDW – Sistema de Data Warehousing
- SGBD – Sistema de Gestão de Bases de Dados

10. Anexos

10.1. Anexo 1




Figura 19: Análise da Cobertura de Dados das Fontes Integradas na Camada Gold




Figura 20: Distribuição Espacial das Estações de Monitorização na Bacia do Mondego




Figura 21: Dimensão das Tabelas do Data Lakehouse




Figura 22: Análise da Distribuição e Segmentação do Risco de Cheias




Figura 23: Evolução Temporal dos Índices de Risco de Cheia nas Principais Estações de Monitorização




Figura 24: Comparação entre os Níveis Atuais e os Níveis Previstos da Água




Figura 25: Comportamento Sazonal dos Níveis Hidrométricos